

Aluno(a): Gabriel Moraes Magalhães
Orientador(a): Édipo Menezes Da Silva

Curso: MBA em Data Science e Analytics EaD.

Benchmarking de Técnicas de Forecasting Aplicadas ao Turismo Brasileiro

Introdução

O setor de turismo global demonstra significativa resiliência econômica e é um dos principais motores na geração de renda e emprego em diversas nações. O Brasil, por exemplo, figura entre as dez maiores potências do turismo em geração de empregos do mundo, além de ser a 13ª nação em previsão de investimentos de capital no setor, conforme dados do *World Travel & Tourism Council* (MINISTÉRIO DO TURISMO, 2025). Essa posição evidencia o peso estratégico da atividade turística para o desenvolvimento socioeconômico do país, tornando o tema uma área prioritária para o aprimoramento de ferramentas de gestão e planejamento.

Apesar da sua relevância, séries temporais de turismo possuem uma natureza inerentemente volátil e sazonal (Nielsen, 2021), o que impõe desafios significativos para a formulação de políticas públicas e a tomada de decisões empresariais. A complexidade de prever com acurácia a demanda e o fluxo de turistas, influenciada por fatores econômicos, eventos globais e variáveis climáticas, representa um gargalo para a otimização de recursos e investimentos. A imprecisão nas estimativas de chegadas de visitantes estrangeiros pode levar tanto à sobrecarga da infraestrutura local em períodos de alta demanda inesperada, quanto ao prejuízo econômico por ociosidade em momentos de baixa. Portanto, antecipar o volume dessa demanda torna-se uma necessidade latente para a sustentabilidade e competitividade do setor.

Para lidar com essa alta complexidade e com a não-linearidade inerente ao comportamento do fluxo turístico, a Ciência de Dados e o Aprendizado de Máquina (*Machine Learning*) emergem como abordagens metodológicas ideais. Em vez de depender exclusivamente de premissas estáticas, os algoritmos de *Machine Learning* são capazes de aprender iterativamente a partir dos dados, identificando padrões ocultos e correlações complexas em grandes séries históricas (GÉRON, 2021). A aplicação dessas técnicas permite transformar o histórico de chegadas de turistas em inteligência preditiva, superando as limitações analíticas dos métodos tradicionais e oferecendo projeções muito mais adaptáveis às flutuações do mundo real.

Diante dessa problemática, o presente projeto de pesquisa propõe uma análise comparativa de diferentes técnicas de análise preditiva de séries temporais. O objetivo

central é definir o melhor método para a previsão da chegada de turistas estrangeiros ao Brasil, avaliando o desempenho de abordagens estatísticas e de *machine learning* para lidar com a complexidade e não-linearidade dos dados.

Para isso, serão comparados modelos tradicionais, como o ARIMA (*Autoregressive Integrated Moving Average*), com métodos modernos, como o XGBoost e arquiteturas avançadas de *deep learning*, como o PatchTST (*Patch Time Series Transformer*) (GUJARATI, 2019; JOSEPH, 2023). Essa comparação visa fornecer subsídios para a escolha de uma ferramenta de *forecasting* robusta e aderente à realidade do turismo brasileiro, contribuindo para um planejamento mais eficiente no setor.

Objetivo

Realizar um *benchmarking* comparativo entre diferentes técnicas de forecasting de séries temporais (incluindo modelos tradicionais como ARIMA e modelos de *machine learning* como XGBoost e PatchTST) para identificar e propor a abordagem preditiva com melhor desempenho e maior aderência na previsão da chegada de turistas estrangeiros ao Brasil.

Material e Métodos

Esta pesquisa caracteriza-se como um estudo quantitativo de caráter aplicado, estruturado sob o delineamento de Implementação de Algoritmos de Machine Learning. O escopo do trabalho consistirá no desenvolvimento e na comparação de diferentes modelos preditivos para séries temporais, focados na projeção da demanda turística internacional no Brasil.

Para a condução do estudo, será realizada a coleta de dados de "Estimativas de Chegadas de Turistas Internacionais ao Brasil", disponibilizados no Portal de Dados Abertos do Brasil (Ministério do Turismo, 2026), compreendendo a série histórica do período de 1989 a 2025. O conjunto de dados original detalha os registros com *features* que incluem ano, mês, via de acesso, continente e país de residência permanente. A organização dessas informações

para a modelagem considerará como variável resposta (*target*) o volume agregado de chegadas de turistas estrangeiros em determinado intervalo de tempo. Adicionalmente, como variáveis explicativas temporais, serão extraídos componentes do próprio histórico, tais como defasagens (*lags*), médias móveis e indicadores de sazonalidade, estruturando o conjunto final de dados para a predição.

O conjunto de dados passará por uma etapa sistemática de pré-processamento, que contemplará o tratamento de valores ausentes, a identificação de possíveis *outliers* e a divisão cronológica em conjuntos de treinamento e teste, garantindo a validação adequada para séries temporais. O processamento analítico será conduzido na linguagem Python, por meio de *notebooks* Jupyter executados em ambiente local.

O ferramental metodológico consistirá na construção, no treinamento e na otimização de três abordagens preditivas distintas:

- Modelos Estatísticos: Será explorado o modelo Autoregressive Integrated Moving Average (ARIMA) para o estabelecimento de uma *baseline* preditiva.
- Aprendizado de Máquina (Machine Learning): Será utilizado o algoritmo XGBoost, baseado na técnica de *gradient boosting* com árvores de decisão.
- Aprendizado Profundo (Deep Learning): Será aplicada a arquitetura avançada PatchTST (Patch Time Series Transformer), com foco na captura de dependências complexas e não-lineares.

A definição da melhor técnica preditiva será fundamentada no *benchmarking* de desempenho dos modelos. A performance estatística será mensurada e comparada a partir das métricas clássicas de erro para séries temporais: Root Mean Squared Error (RMSE), Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE) e o Coeficiente de Determinação (R^2).

Adicionalmente, para atestar a viabilidade e a aderência das soluções à realidade operacional do setor, os modelos serão avaliados sob critérios técnicos de engenharia de software: o grau de explicabilidade gerado por cada algoritmo, a escalabilidade computacional e o tempo de treinamento requerido. Para garantir a isonomia dessa avaliação de performance computacional e permitir a reprodução do estudo, todos os modelos serão treinados sob uma mesma infraestrutura local de hardware.

Resultados Esperados

Ao término desta pesquisa, espera-se identificar qual das abordagens preditivas avaliadas (ARIMA, XGBoost ou PatchTST) apresenta a maior acurácia e confiabilidade na projeção do fluxo de turistas internacionais para o Brasil. Do ponto de vista técnico, a expectativa é quantificar de forma objetiva o *trade-off* entre o desempenho preditivo, mensurado por métricas de erro padronizadas e os custos de engenharia associados a cada solução. Com isso, busca-se evidenciar se o emprego de arquiteturas complexas de *Deep Learning* justifica o maior consumo de recursos computacionais e a menor explicabilidade, quando comparado a modelos estatísticos tradicionais e algoritmos clássicos de *Machine Learning*.

Adicionalmente, no âmbito prático e gerencial, espera-se que este *benchmarking* forneça um embasamento empírico e metodológico robusto para o setor de turismo. Os resultados almejam servir como um instrumento tecnológico de apoio à tomada de decisão para órgãos públicos e iniciativas privadas, permitindo um planejamento estratégico mais eficiente. Espera-se que as previsões geradas auxiliem na alocação otimizada de recursos, na formulação de políticas de incentivo mais precisas e na mitigação proativa dos impactos gerados pela sazonalidade e pela volatilidade inerentes à demanda turística nacional.

Cronograma de Atividades

Atividades planejadas	Mês						
	Mar	Abr	Mai	Jun	Jul	Ago	Set
Revisão bibliográfica	X						
Escrita do projeto de pesquisa	X						
Processamento e organização dos dados		X					
Análise dos dados		X	X	X	X		
Escrita dos resultados preliminares			X	X	X		
Redação final do TCC					X	X	
Entrega do TCC						X	X

Elaboração dos slides							X
Defesa do TCC							X

Referências

Géron, A. 2021. Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras & TensorFlow. 2ed. Alta Books, Rio de Janeiro, RJ, Brasil.

Gujarati, D. N. 2019. Econometria: Princípios, teoria e aplicações práticas. 1 ed. Saraivauni, Porto Alegre, Brasil.

Joseph, M.; Tackes, J. 2024. Modern time series forecasting with python. 1 ed. Packt Publishing, Birmingham, Reino Unido.

Ministério do Turismo. 2025. Brasil está entre as 10 maiores potências globais do turismo em geração de empregos, aponta WTTC. Disponível em: <<https://www.gov.br/turismo/pt-br/assuntos/noticias/brasil-esta-entre-as-10-maiores-potencias-globais-do-turismo-em-geracao-de-empregos-aponta-wttc>>. Acesso em: 18 mar. 2026.

Ministério do Turismo. 2026. Estimativas de chegadas de turistas internacionais ao Brasil. Disponível em: <<https://dados.gov.br/dados/conjuntos-dados/estimativas-de-chegadas-de-turistas-internacionais-ao-brasil>>. Acesso em: 18 mar. 2026.

Nielsen, A. 2021. Análise Prática de Séries Temporais: Predição com Estatística e Aprendizado de Máquina. 1 ed. Alta Books, Rio de Janeiro, RJ, Brasil.