

Benchmarking de Técnicas de Forecasting Aplicadas ao Turismo Brasileiro

Gabriel Moraes Magalhães^{1*}; Édipo Menezes Da Silva²

^{1*} Tecnólogo em Data Science. E-mail: gabrielmoraesmagalhaes@gmail.com

^{2*} Doutorando em Estatística Agrícola e Experimentação. E-mail: ediposvm01@gmail.com

Benchmarking de Técnicas de Forecasting Aplicadas ao Turismo Brasileiro

Introdução

O setor de turismo global demonstra significativa resiliência econômica e é um dos principais motores na geração de renda e emprego em diversas nações. O Brasil, por exemplo, figura entre as dez maiores potências do turismo em geração de empregos do mundo, além de ser a 13ª nação em previsão de investimentos de capital no setor, conforme dados do *World Travel & Tourism Council* (MINISTÉRIO DO TURISMO, 2025). Essa posição evidencia o peso estratégico da atividade turística para o desenvolvimento socioeconômico do país, tornando o tema uma área prioritária para o aprimoramento de ferramentas de gestão e planejamento.

Apesar da sua relevância, séries temporais de turismo possuem uma natureza inerentemente volátil e sazonal (Nielsen, 2021), o que impõe desafios significativos para a formulação de políticas públicas e a tomada de decisões empresariais. A complexidade de prever com acurácia a demanda e o fluxo de turistas, influenciada por fatores econômicos, eventos globais e variáveis climáticas, representa um gargalo para a otimização de recursos e investimentos. A imprecisão nas estimativas de chegadas de visitantes estrangeiros pode levar tanto à sobrecarga da infraestrutura local em períodos de alta demanda inesperada, quanto ao prejuízo econômico por ociosidade em momentos de baixa. Portanto, antecipar o volume dessa demanda torna-se uma necessidade latente para a sustentabilidade e competitividade do setor.

Para lidar com essa alta complexidade e com a não-linearidade inerente ao comportamento do fluxo turístico, a Ciência de Dados e o Aprendizado de Máquina (*Machine Learning*) emergem como abordagens metodológicas ideais. Em vez de depender exclusivamente de premissas estáticas, os algoritmos de *Machine Learning* são capazes de aprender iterativamente a partir dos dados, identificando padrões ocultos e correlações complexas em grandes séries históricas (GÉRON, 2021). A aplicação dessas técnicas permite transformar o histórico de chegadas de turistas em inteligência preditiva, superando as limitações analíticas dos métodos tradicionais e oferecendo projeções muito mais adaptáveis às flutuações do mundo real.

Diante dessa problemática, o presente projeto de pesquisa propõe uma análise comparativa de diferentes técnicas de análise preditiva de séries temporais. O objetivo central é definir o melhor método para a previsão da chegada de turistas estrangeiros ao

Brasil, avaliando o desempenho de abordagens estatísticas e de *machine learning* para lidar com a complexidade e não-linearidade dos dados.

Para isso, serão comparados modelos tradicionais, como o ARIMA (*Autoregressive Integrated Moving Average*), com métodos modernos, como o XGBoost e arquiteturas avançadas de *deep learning*, como o PatchTST (*Patch Time Series Transformer*) (GUJARATI, 2019; JOSEPH, 2023). Essa comparação visa fornecer subsídios para a escolha de uma ferramenta de *forecasting* robusta e aderente à realidade do turismo brasileiro, contribuindo para um planejamento mais eficiente no setor.

Material e Métodos

Esta pesquisa caracteriza-se como um estudo quantitativo de caráter aplicado, estruturado sob o delineamento de Implementação de Algoritmos de Machine Learning. O escopo do trabalho consistirá no desenvolvimento e na comparação de diferentes modelos preditivos para séries temporais, focados na projeção da demanda turística internacional no Brasil.

Para a condução do estudo, será realizada a coleta de dados de "Estimativas de Chegadas de Turistas Internacionais ao Brasil", disponibilizados no Portal de Dados Abertos do Brasil (Ministério do Turismo, 2026), compreendendo a série histórica do período de 1989 a 2025. O conjunto de dados original detalha os registros com *features* que incluem ano, mês, via de acesso, continente e país de residência permanente. A organização dessas informações para a modelagem considerará como variável resposta (*target*) o volume agregado de chegadas de turistas estrangeiros em determinado intervalo de tempo. Adicionalmente, como variáveis explicativas temporais, serão extraídos componentes do próprio histórico, tais como defasagens (*lags*), médias móveis e indicadores de sazonalidade, estruturando o conjunto final de dados para a predição.

O conjunto de dados passará por uma etapa sistemática de pré-processamento, que contemplará o tratamento de valores ausentes, a identificação de possíveis *outliers* e a divisão cronológica em conjuntos de treinamento e teste, garantindo a validação adequada para séries temporais. O processamento analítico será conduzido na linguagem Python, por meio de *notebooks* Jupyter executados em ambiente local.

O ferramental metodológico consistirá na construção, no treinamento e na otimização de três abordagens preditivas distintas:

Modelos Estatísticos: Será explorado o modelo Autoregressive Integrated Moving Average [ARIMA] para o estabelecimento de uma "baseline" preditiva.

Aprendizado de Máquina [Machine Learning]: Será utilizado o algoritmo XGBoost, baseado na técnica de "gradient boosting" com árvores de decisão.

Aprendizado Profundo [Deep Learning]: Será aplicada a arquitetura avançada Patch Time Series Transformer [PatchTST], com foco na captura de dependências complexas e não-lineares.

A definição da melhor técnica preditiva será fundamentada no *benchmarking* de desempenho dos modelos. A performance estatística será mensurada e comparada a partir das métricas clássicas de erro para séries temporais: Root Mean Squared Error (RMSE), Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE) e o Coeficiente de Determinação (R^2).

Adicionalmente, para atestar a viabilidade e a aderência das soluções à realidade operacional do setor, os modelos serão avaliados sob critérios técnicos de engenharia de software: o grau de explicabilidade gerado por cada algoritmo, a escalabilidade computacional e o tempo de treinamento requerido. Para garantir a isonomia dessa avaliação de performance computacional e permitir a reprodução do estudo, todos os modelos serão treinados sob uma mesma infraestrutura local de hardware.

Resultados Preliminares

Consolidação e Preparação da Base de Dados

A base bruta foi obtida a partir do download manual dos arquivos anuais de chegadas de turistas internacionais disponibilizados pelo Ministério do Turismo, cobrindo o período de janeiro de 1989 a dezembro de 2025. A unificação dos arquivos exigiu o tratamento dos cabeçalhos, que sofreram alterações de nomenclatura e de codificação ao longo dos anos, padronizadas por meio de um mapeamento de colunas. O conjunto consolidado totalizou 978.472 registros granulares, descritos por via de acesso, unidade federativa de destino, país de origem, mês e ano.

Na etapa de limpeza, os registros sem valor de chegadas, correspondentes a 1,01% do total e que apenas indicavam que não houve chegadas em determinado mês, foram removidos. Procedeu-se à correção sistemática de inconsistências de codificação de caracteres e à padronização categórica de vias de acesso, estados e países. A partir dos campos de data, construiu-se o índice temporal mensal, e foram derivadas duas variáveis de agregação geográfica e cultural: a região da unidade federativa de destino e a subdivisão cultural do país de origem, esta última agrupando os 208 países em oito blocos (LATAM, Europa Ocidental / Oriental, Anglo-América, APAC, Países Nórdicos / Bálticos, África Subsaariana, MENA e Outros). Ao final, a base apresentou ausência total de valores nulos.

A partição entre treino e teste foi realizada de forma estritamente cronológica, conforme recomendado para séries temporais: o conjunto de treino abrangeu o período de janeiro de 1989 a dezembro de 2024, e o conjunto de teste foi reservado para os doze meses de 2025 (janeiro a dezembro), utilizados na avaliação final de todos os modelos. Não foi reservada uma partição de validação final, pois considerou-se que a separação treino/teste/validação teria impacto na quantidade de dados disponível para treinamento dos modelos, especialmente considerando períodos após a pandemia de COVID-19.

Análise Exploratória dos Dados

A análise exploratória foi conduzida em duas frentes: a caracterização das variáveis categóricas e a investigação das propriedades estruturais da série temporal mensal agregada.

A análise categórica evidenciou forte concentração em todas as dimensões. A via aérea respondeu por 66,7% das chegadas históricas, seguida pela via terrestre (30,7%), enquanto as vias marítima e fluvial somaram menos de 3%. Quanto ao destino, observou-se a predominância da Região Sudeste (56,4%) e da Região Sul (31,6%), com São Paulo (36,2%) e Rio de Janeiro (19,7%) concentrando a maior parte das chegadas. No que tange à origem, a Argentina liderou de forma isolada (29,0%), seguida pelos Estados Unidos (11,3%), o que se reflete na predominância do bloco LATAM (53,1%) sobre Europa Ocidental/Oriental (22,9%) e Anglo-America (15,6%), conforme apresentado na Figura 1.




Figura 1. Distribuição percentual das chegadas de turistas internacionais por subdivisão cultural de origem (1989–2024)

Fonte: Resultados originais da pesquisa

Através da análise categórica, foi possível identificar, por exemplo, um fluxo de entrada de turistas argentinos por via terrestre sazonalmente durante o mês de janeiro, o que pode ser evidenciado nas Figuras 2 e 3.




Figura 2. Chegada de turistas por Via de Acesso (2016–2024)

Fonte: Resultados originais da pesquisa




Figura 3. Mapa de calor dos dez maiores países em média de chegada de turistas, organizados em ordem alfabética, por mês (1989–2024)
Fonte: Resultados originais da pesquisa

A análise da série temporal mensal agregada revelou quatro regimes distintos de comportamento, delimitados para fins analíticos em período histórico (anterior a 2000), pré-pandêmico (2000–2019), pandêmico (2020–2021) e pós-pandêmico (a partir de 2022). A visão integral da série tornou explícito o colapso abrupto provocado pela pandemia de COVID-19 e a subsequente recuperação acelerada, como mostrado na Figura 4.




Figura 4. Série temporal mensal de chegadas de turistas internacionais ao Brasil, segmentada por período analítico (1989–2024)
Fonte: Resultados originais da pesquisa

A caracterização estatística por período confirmou a singularidade do intervalo pandêmico (Figura 5). Enquanto os períodos pré e pós-pandêmico apresentaram médias mensais equivalentes, 454.090 e 453.110 chegadas, respectivamente (Figura 5, painel A), o período pandêmico registrou média de apenas 120.512 chegadas, com mediana de 41.008 (Figura 5, painel B), expressando a assimetria interna do período. O coeficiente de variação pandêmico atingiu 192,4%, contra 36,9% no pré-pandêmico e 45,6% no pós-pandêmico (Figura 5, painel C), evidenciando a quebra estrutural que justificou o tratamento dedicado descrito no subtópico seguinte.




Figura 5. Estatísticas descritivas mensais das chegadas de turistas internacionais ao Brasil por período analítico

Fonte: Resultados originais da pesquisa

Nota: A) Média mensal de chegadas; B) Mediana mensal de chegadas; C) Coeficiente de variação (%); D) Amplitude (máximo - mínimo)

A investigação da tendência, conduzida com regressão linear e polinomial (conforme Figura 6), médias móveis e filtro de Hodrick-Prescott (conforme Figura 7), demonstrou que a série não possui tendência monotônica: identificou-se um pico de tendência por volta de 2016, seguido de retração no fim do período pré-pandêmico e de recuperação acentuada no pós-pandemia. Esse comportamento não monotônico desaconselhou o uso de um termo determinístico de tendência e fundamentou a opção pela diferenciação estocástica na modelagem.




Figura 6. Estimativa de tendência linear e polinomial das chegadas mensais de turistas internacionais ao Brasil por período analítico

Fonte: Resultados originais da pesquisa

Nota: A) Período pré-pandêmico (2000–2019); B) Período pandêmico (2020–2021); C) Período pós-pandêmico (2022–2024). As linhas sólidas vermelhas representam a tendência linear e as linhas tracejadas roxas a tendência polinomial de segundo grau. R^2 lin: coeficiente de determinação da regressão linear; R^2 poly: coeficiente de determinação da regressão polinomial




Figura 7. Decomposição de tendência da série pelo filtro de Hodrick-Prescott e média móvel de doze meses

Fonte: Resultados originais da pesquisa

Nota: MM: média móvel; HP: filtro de Hodrick-Prescott ($\lambda = 129.600$)

O diagnóstico da natureza da decomposição, baseado na correlação entre média e desvio-padrão anuais, indicou comportamento multiplicativo em todos os subperíodos não pandêmicos (correlação de 0,850 no pré-pandêmico e 0,975 no pós-pandêmico), o que sustentou a aplicação da transformação logarítmica à variável-alvo de forma consistente ao longo de todo o pipeline.

A decomposição STL confirmou a dominância do componente sazonal sobre a variância da série. A força sazonal, medida como a fração da variância explicada pelo componente sazonal, atingiu 0,80 no período pré-pandêmico e 0,91 no pós-pandêmico, com sazonalidade anual (período 12) preservada após a pandemia e pico recorrente no mês de janeiro em todos os regimes, o que pode ser observado.




Figura 8. Componente sazonal STL da série de chegadas internacionais ao Brasil por período, em escala logarítmica

Fonte: Resultados originais da pesquisa

Nota: A força sazonal foi calculada como $1 - \text{Var}(\text{Resíduo}) / \text{Var}(\text{Sazonal} + \text{Resíduo})$ a partir da decomposição STL aplicada a cada subperíodo. Os painéis A, B e C correspondem, respectivamente, aos períodos pré-pandêmico (2000–2019), pandêmico (2020–2021) e pós-pandêmico (2022–2025)

Por fim, os testes de estacionariedade ADF e KPSS foram aplicados de forma conjunta sobre múltiplas transformações da série. A série em nível mostrou-se não estacionária, ao passo que a combinação de uma diferenciação simples e uma diferenciação sazonal sobre a série logaritimizada produziu um veredito conjunto de estacionariedade. Esse resultado fundamentou a especificação dos parâmetros de diferenciação dos modelos SARIMA em $d = 1$ e $D = 1$, com período sazonal $s = 12$. As funções de autocorrelação (ACF) e autocorrelação parcial (PACF), inspecionadas sobre a série diferenciada, orientaram as faixas de busca dos parâmetros autorregressivos e de médias móveis.




Figura 9. p-valores dos testes de estacionariedade Dickey-Fuller Aumentado e Kwiatkowski-Phillips-Schmidt-Shin aplicados à série de chegadas mensais por período analítico e transformação

Fonte: Resultados originais da pesquisa

Nota: A) Teste Dickey-Fuller Aumentado [ADF]: H_0 = raiz unitária (não estacionária); células verdes indicam rejeição de H_0 ($p < 0,05$); B) Teste Kwiatkowski-Phillips-Schmidt-Shin [KPSS]: H_0 = estacionariedade; células verdes indicam não rejeição de H_0 ($p \geq 0,05$). Diff(1): diferenciação de primeira ordem; Diff(12): diferenciação sazonal de período 12; Log: transformação logarítmica natural

A Tabela 1 sintetiza as decisões estruturais de modelagem derivadas da análise exploratória

Tabela 1. Decisões estruturais de modelagem derivadas da análise exploratória

Propriedade investigada	Diagnóstico	Decisão de modelagem
Tendência	Não monotônica (pico ~2016)	Diferenciação estocástica ($d = 1$)
Sazonalidade	Anual, forte (força 0,80–0,91)	Diferenciação sazonal ($D = 1, s = 12$)
Tipo de decomposição	Multiplicativa (corr. 0,85–0,98)	Transformação logarítmica
Estacionariedade	Estacionária após $\log + d = 1 + D = 1$	SARIMA($p, 1, q$)($P, 1, Q$)[12]

Fonte: Resultados originais da pesquisa

Tratamento do Período Pandêmico

Dada a quebra estrutural identificada no intervalo de 2020–2021, investigou-se de forma sistemática a melhor estratégia para lidar com esse período. Foram avaliados seis métodos de imputação: interpolação linear, STL + PCHIP, *spline* cúbica, *Auto ARIMA* progressivo (*forward*), *Auto ARIMA* regressivo (*backward*) e uma combinação ponderada (*blend*) dos dois últimos, sobre treze janelas pré-pandêmicas simuladas, com comprimentos variando de 6 a 36 meses. Cada método foi avaliado por métricas de reconstrução (MAE, RMSE, MAPE e razão de variância) e por uma métrica de desempenho a jusante (*downstream*), construída de forma livre de vazamento, que mede o impacto da imputação sobre a previsão de doze meses seguintes. Os resultados obtidos foram agregados na Tabela 2, a seguir.

Tabela 2. Desempenho médio dos métodos de imputação no benchmark de janelas simuladas

Método	MAPE (%)	Razão de variância	DS-RMSE	DS-MAPE (%)
Auto ARIMA (forward)	26,75	0,526	99.237	19,60
STL + PCHIP	64,03	1,316	103.114	20,84
ARIMA blend	40,30	0,484	109.062	21,63
Linear	64,72	0,471	114.993	22,75

Auto ARIMA (backward)	77,05	0,610	127.721	25,62
Spline	222,13	7,850	215.686	43,99

Fonte: Resultados originais da pesquisa

Embora o *benchmark* multi-janelas tenha apontado o *Auto ARIMA* progressivo como o método de melhor ranqueamento médio, o teste no intervalo real da pandemia revelou um resultado distinto e determinante para a estratégia de modelagem. Ao imputar o intervalo real de 2020–2021 e prever o ano de 2024, observou-se que o cenário sem imputação, isto é, o treinamento restrito aos dados pós-pandêmicos (a partir de 2022), superou todos os métodos de imputação, atingindo o menor erro percentual (MAPE de 11,78%). Esse achado evidenciou que o melhor desempenho em reconstrução pontual ou em *benchmarks* sintéticos não se traduz necessariamente em melhor desempenho preditivo no cenário real, e direcionou a modelagem estatística para uma abordagem baseada na janela pós-pandêmica. Os resultados das imputações de dados para o período pandêmico podem ser verificados na Tabela 3.




Figura 10. Imputações do intervalo pandêmico e previsões para 2024 por método, sobre a série real

Fonte: Resultados originais da pesquisa

Tabela 3. Erro de previsão para 2024 segundo o tratamento do período pandêmico

Tratamento	RMSE	MAPE (%)
Apenas pós-COVID (sem imputação)	102.880	11,78
STL + PCHIP	129.427	14,82
Auto ARIMA (forward)	142.729	15,70
Linear	156.273	17,73
ARIMA blend	134.081	19,61
Auto ARIMA (backward)	127.764	19,96
Spline	130.731	20,77

Fonte: Resultados originais da pesquisa

Modelagem Estatística: SARIMAX

O modelo estatístico foi estabelecido como linha de base do estudo comparativo. Com os parâmetros de diferenciação fixados a partir dos testes de estacionariedade ($d = 1$, $D = 1$, $s = 12$), conduziu-se uma busca em grade combinando 36 configurações de ordens, com $p, q \in \{0,1,2\}$ e $P, Q \in \{0,1\}$, com 14 estratégias de seleção de dados de treino, totalizando 504 modelos avaliados. As estratégias de treino contemplaram janelas móveis de 4 a 14 anos com regressores exógenos para a pandemia, bem como o uso exclusivo do período pós-pandêmico, com e sem um regressor exógeno de recuperação para o intervalo de janeiro a junho de 2022. Todos os modelos foram ajustados sobre a série logaritmizada, e avaliados no conjunto de teste de 2025 pelas métricas RMSE, MAE, MAPE e R^2 .

A configuração de melhor desempenho confirmou a conclusão obtida no tratamento do período pandêmico: o modelo vencedor utilizou a janela pós-pandêmica acrescida do regressor de recuperação, com especificação SARIMAX(1,1,2)(1,1,1)[12], alcançando RMSE de 64.174, MAPE de 7,3% e R^2 de 0,959 no conjunto de teste. As demais configurações de melhor desempenho também se concentraram em janelas pós-pandêmicas ou recentes, reforçando que a restrição do treino ao regime pós-pandêmico foi mais eficaz do que a incorporação do período pandêmico via imputação ou via regressores exógenos sobre janelas longas. Os resultados obtidos podem ser apresentados

na Tabela 4 e os resultados do melhor modelo selecionado podem ser visualizados na Figura 11.

Tabela 4. Melhores configurações SARIMAX no conjunto de teste (janeiro a dezembro de 2025)

Seleção de dados	Ordem	RMSE	MAPE (%)	R ²
Pós-COVID + exog recuperação	(1,1,2)(1,1,1)[12]	64.174	7,3	0,959
Pós-COVID	(2,1,2)(1,1,1)[12]	74.272	7,1	0,945
Pós-COVID + exog recuperação	(2,1,2)(1,1,1)[12]	79.195	7,2	0,938
Últimos oito anos + exog recuperação	(2,1,1)(1,1,0)[12]	83.432	7,5	0,931

Fonte: Resultados originais da pesquisa




Figura 11. Previsão do modelo SARIMA(1,1,2)(1,1,1)[12] com variável exógena de recuperação pós-pandêmica para chegadas internacionais mensais ao Brasil

Fonte: Resultados originais da pesquisa

Nota: A linha olive representa os últimos 24 meses do conjunto de treino (2023–2024); a linha preta representa os valores reais do conjunto de teste (2025–2026); a linha tracejada vermelha representa os valores previstos pelo modelo. RMSE = 64.174; MAPE = 7,3%; R² = 0,959

A análise dos resíduos dos melhores modelos, por meio de gráficos de resíduos padronizados, histograma com densidade estimada e gráfico quantil-quantil normal, indicou ausência de estrutura sistemática remanescente, com a maior parte das observações aderindo à distribuição normal de referência. A qualidade do ajuste foi corroborada pela sobreposição entre a previsão e os valores reais de 2025.

O modelo estatístico assim estabelecido constitui a linha de base sobre a qual os modelos de aprendizado de máquina (XGBoost) e de aprendizado profundo (PatchTST) serão comparados nas etapas subsequentes da pesquisa, completando o *benchmarking* proposto no objetivo do trabalho.

Cronograma de Atividades

Atividades planejadas	Mês						
	Mar	Abr	Mai	Jun	Jul	Ago	Set
Revisão bibliográfica	X						
Escrita do projeto de pesquisa	X						
Processamento e organização dos dados		X					
Análise dos dados		X	X	X	X		
Escrita dos resultados preliminares			X	X	X		
Redação final do TCC					X	X	
Entrega do TCC						X	X
Elaboração dos slides							X
Defesa do TCC							X

Referências

Géron, A. 2021. *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras & TensorFlow*. 2ed. Alta Books, Rio de Janeiro, RJ, Brasil.

Gujarati, D. N. 2019. *Econometria: Princípios, teoria e aplicações práticas*. 1 ed. Saraivauni, Porto Alegre, Brasil.

Joseph, M.; Tackes, J. 2024. *Modern time series forecasting with python*. 1 ed. Packt Publishing, Birmingham, Reino Unido.

Ministério do Turismo. 2025. Brasil está entre as 10 maiores potências globais do turismo em geração de empregos, aponta WTTC. Disponível em:
<<https://www.gov.br/turismo/pt-br/assuntos/noticias/brasil-esta-entre-as-10-maiores-potencias-globais-do-turismo-em-geracao-de-empregos-aponta-wttc>>. Acesso em: 18 mar. 2026.

Ministério do Turismo. 2026. Estimativas de chegadas de turistas internacionais ao Brasil. Disponível em:
<<https://dados.gov.br/dados/conjuntos-dados/estimativas-de-chegadas-de-turistas-internacionais-ao-brasil>>. Acesso em: 18 mar. 2026.

Nielsen, A. 2021. Análise Prática de Séries Temporais: Predição com Estatística e Aprendizado de Máquina. 1 ed. Alta Books, Rio de Janeiro, RJ, Brasil.