Mudança de regime compromete a seleção de modelos de previsão do turismo internacional brasileiro

Gabriel Moraes Magalhães
Orientador: Édipo Menezes Da Silva

Contexto do mercado de turismo no Brasil

7º

país que mais gerou empregos no turismo, com 8,21 milhões de postos previstos para 2025

12º

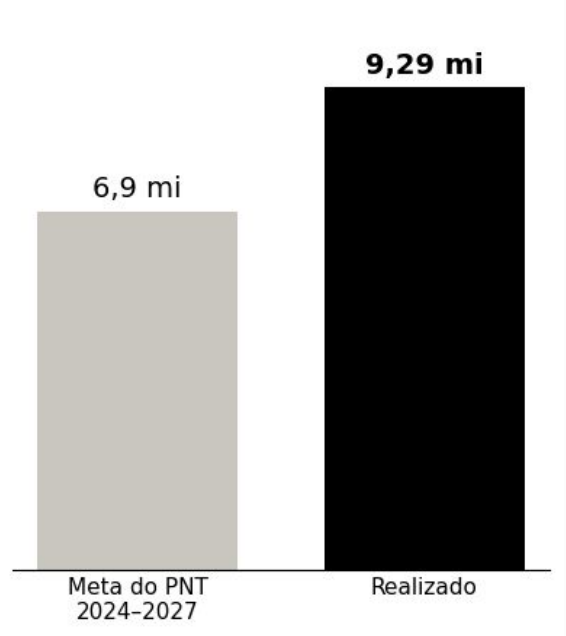
em contribuição do turismo ao PIB, estimada em US$ 167,6 bilhões

Fonte: World Travel & Tourism Council, via MTUR (2025)

Infraestrutura, promoção internacional e metas públicas **dependem de previsões de demanda**

Erros geram capacidade ociosa ou saturação de destinos

Chegadas de turistas estrangeiros em 2025 (milhões)



Fonte: Agência Brasil (2026)

+34,6%

acima da meta oficial de chegadas

+37,1%

sobre 2024 (9.287.196 turistas)

Em seis anos: queda abrupta, recuperação e aceleração sem precedentes, um desafio para métodos que extrapolam o passado

A seleção por validação supõe continuidade do regime

Famílias de modelos na previsão da demanda turística

Séries Temporais

Modelos estatísticos consolidados usados para forecasting. Forte dependência de observações passadas

Aprendizado de Máquina

Modelos baseados em atributos defasados da própria série. Tem dificuldade em extrapolar valores novos

Modelos Fundacionais

Pré-treinados em grandes coleções de séries. Preveem séries novas sem treinamento

Janelas de validação

configuração escolhida pelo desempenho no passado recente



Período de uso

a melhor no passado recente pode ser justamente a que mais erra

Lacuna: risco raramente medido, estudos comparativos costumam reportar um único período de teste

Objetivo



Comparar **SARIMAX**, **aprendizado de máquina local e global**, o modelo fundacional **TimesFM** e **combinações** na previsão mensal das chegadas de turistas internacionais ao Brasil, com **12 meses de antecedência**

1 **Pergunta 1**

Qual abordagem a validação em múltiplas origens seleciona?

2 **Pergunta 2**

A classificação obtida na validação se mantém em um ano de teste posterior à mudança de regime de 2025?

Série mensal de 1989 a 2026, com teste isolado

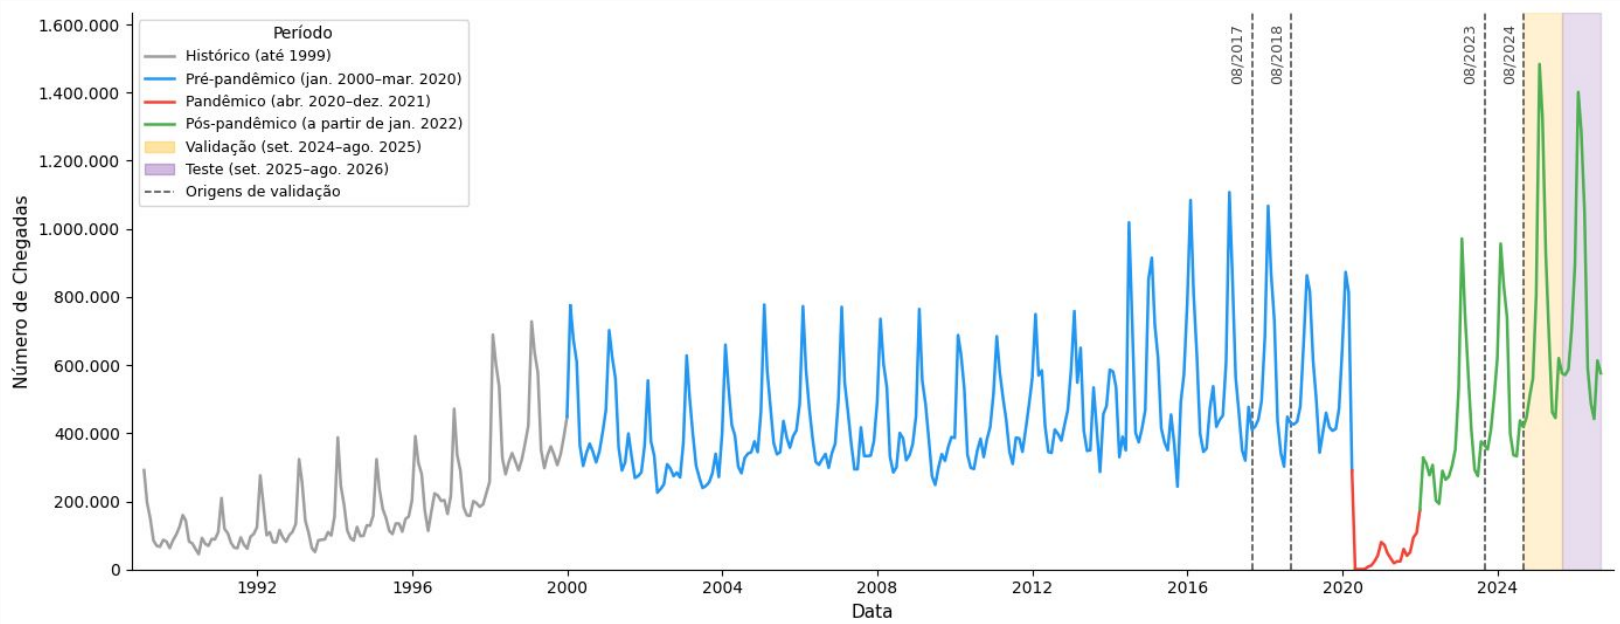


Figura 1. Chegadas mensais de turistas internacionais ao Brasil (jan/1989–ago/2026), com os períodos analíticos, as quatro origens de validação e o ano de teste. Fonte: Dados originais da pesquisa

Treino
jan/1989–ago/2024 · 428 meses

Validação
set/2024–ago/2025

Teste
set/2025–ago/2026

Portal de Dados Abertos do MTUR
38 arquivos CSV, jan/1989–ago/2026

995.126 registros
por via de acesso, UF de entrada e país de residência

452 observações mensais
alvo: total mensal de chegadas

Teste lido uma única vez
seleção usou apenas treino e validação

Diagnósticos da série temporal analisada

66,5%

das chegadas por via aérea; 30,8% por via terrestre

53,7%

do bloco LATAM; Argentina lidera com 29,5%

Janeiro

pico de verão, puxado por argentinos por via terrestre

Diagnóstico	Pré-pandêmico	Pós-pandêmico	Implicação
Tendência (ADF com constante vs. com tendência)	Estocástica	Determinística (44 meses)	Diferenciação simples incluída na grade
Correlação média–desvio-padrão anual	0,897	0,992	Comportamento multiplicativo; logaritmo e Box-Cox testados
Força sazonal (STL)	0,767	0,936	Sazonalidade anual dominante; diferenciação sazonal
λ de Box-Cox (Guerrero)	−0,43	−0,04	Transformação tratada como hiperparâmetro
Estacionariedade (ADF e KPSS)	Após Diff(1) e Diff(12)	Após Diff(1) e Diff(12)	SARIMA(p, 1, q)(P, 1, Q)[12] como referência

Fonte: Resultados originais da pesquisa. Diff(1): diferenciação simples; Diff(12): diferenciação sazonal de período 12

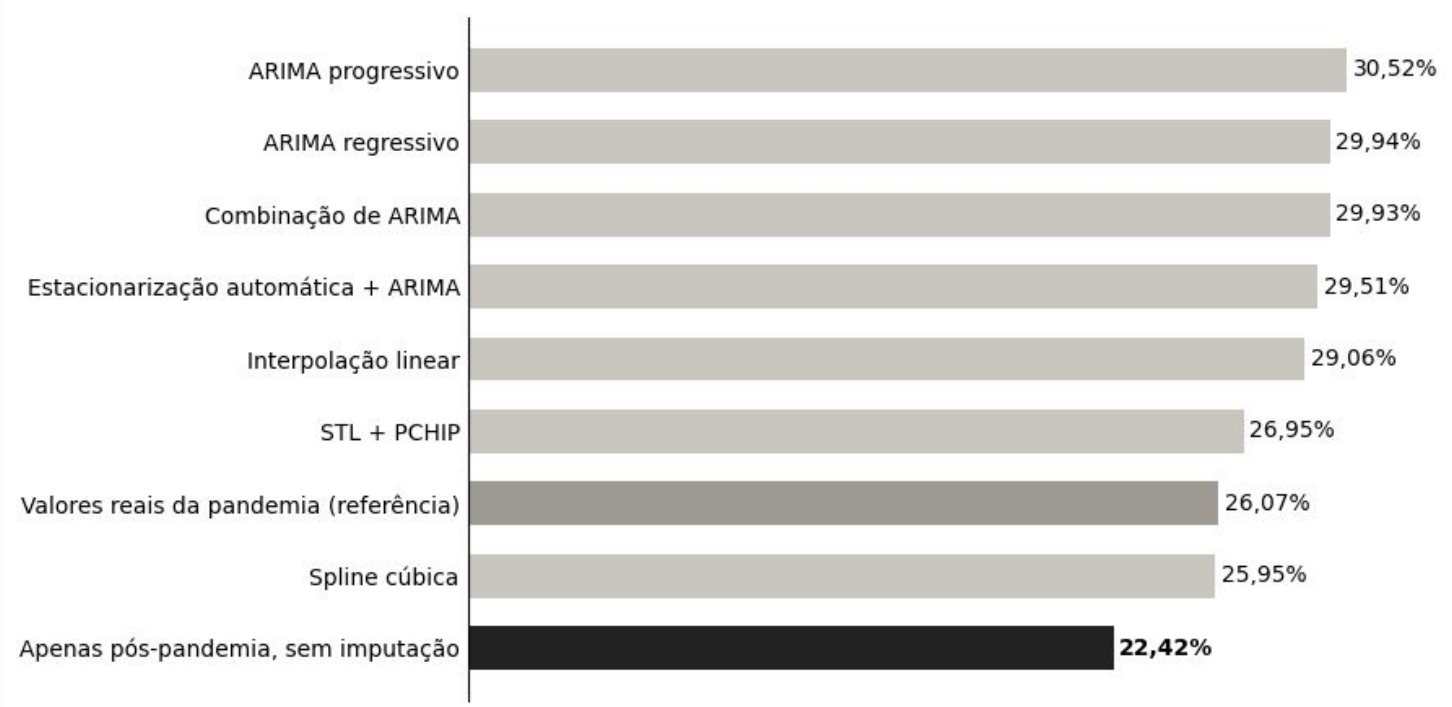
Teste de possíveis imputações para a janela pandêmica

7 métodos de imputação
interpolação, STL + PCHIP, spline cúbica e variantes de ARIMA

13 janelas simuladas
6 a 36 meses pré-pandêmicos (1995–2015) mascarados e reconstruídos

Reconstrução ≠ previsão
ARIMA reconstruiu melhor e a spline foi instável (MAPE > 200%), mas a ordem não se repetiu na previsão

MAPE na previsão do ano de validação após imputar a lacuna real



A dificuldade não estava na lacuna, mas na aceleração do fim de 2024, sendo assim, **a pandemia virou escolha da grade** (indicadores, remoção ou máscara)

Validação em quatro origens e teste lido uma única vez

Origem **ago/2017**
set/2017–ago/2018

+2,8%
crescimento anual

Origem **ago/2018**
set/2018–ago/2019

−3,7%
crescimento anual

Origem **ago/2023**
set/2023–ago/2024

+15,7%
crescimento anual

Origem **ago/2024**
set/2024–ago/2025

+39,6%
crescimento anual

Teste
set/2025–ago/2026

previsões congeladas antes da leitura

Cada origem usa apenas o histórico disponível até aquele mês e prevê os 12 meses seguintes

Seleção: MASE sazonal

- Erro absoluto médio da previsão (h = 12) dividido pelo erro do ingênuo sazonal no histórico
- **< 1**: erra menos que repetir o mesmo mês do ano anterior
- Ordenação pela média das 4 origens; pior origem como estabilidade

Avaliação no ano de teste

- Reajuste até ago/2025, reproduzindo a validação com diferença < 10^{-6}
- Previsões congeladas por SHA-256 antes de ler o teste
- Concordância validação × teste: correlação de Spearman

Cinco abordagens avaliadas sob o mesmo protocolo

SARIMAX

6.048

configurações

144 ordens × 3 tratamentos do alvo × 14 seleções de treino

Ajuste: Máxima verossimilhança

ML local

2.880

configurações

Ridge, Lasso, LightGBM e XGBoost; estratégia recursiva ou direta

Ajuste: Optuna, 40 tentativas

ML global

432

configurações

Painel de 21 séries (86,2% das chegadas); total pela soma

Ajuste: Optuna, 25 tentativas

TimesFM 3.0

360

configurações

Varia contexto, pandemia, alvo, covariáveis e média simétrica

Ajuste: Sem treinamento

Combinações

13

configurações

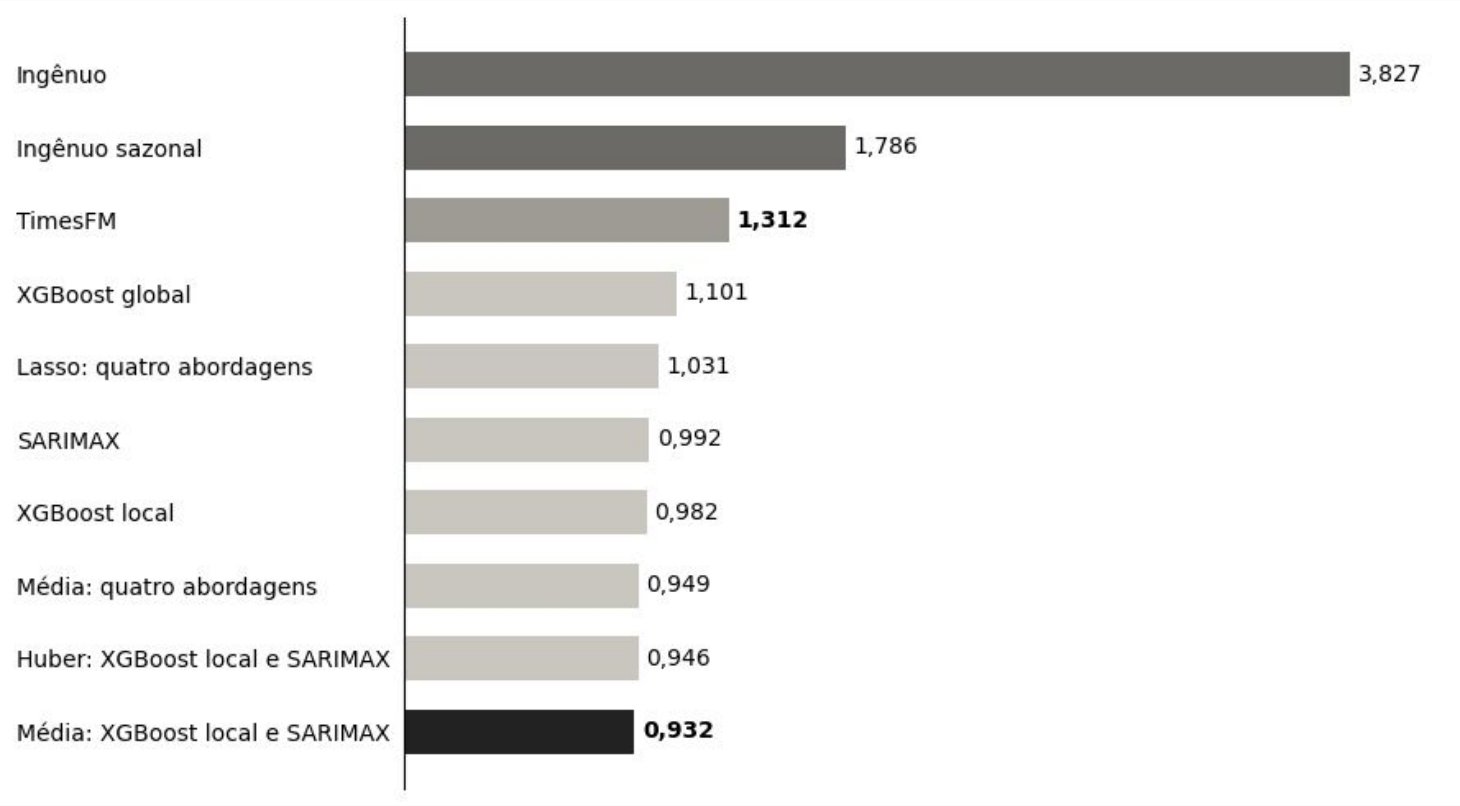
Média, mediana, inverso do MASE e empilhamento

Ajuste: Pesos deixando uma origem de fora

Sem vazamento: atributos derivados do alvo deslocados pelo passo de previsão e teste de perturbação (valores após o corte × 10). **Diferença sazonal do log** permite às árvores prever acima do máximo do treino.

Na validação, a média XGBoost + SARIMAX venceu

MASE sazonal médio nas 4 origens (menor é melhor)



Fonte: Resultados originais da pesquisa (Tabela 4 e Figura 5)

0,932 | 1,066

menor MASE médio e menor pior caso: a escolha natural para o uso

4,024

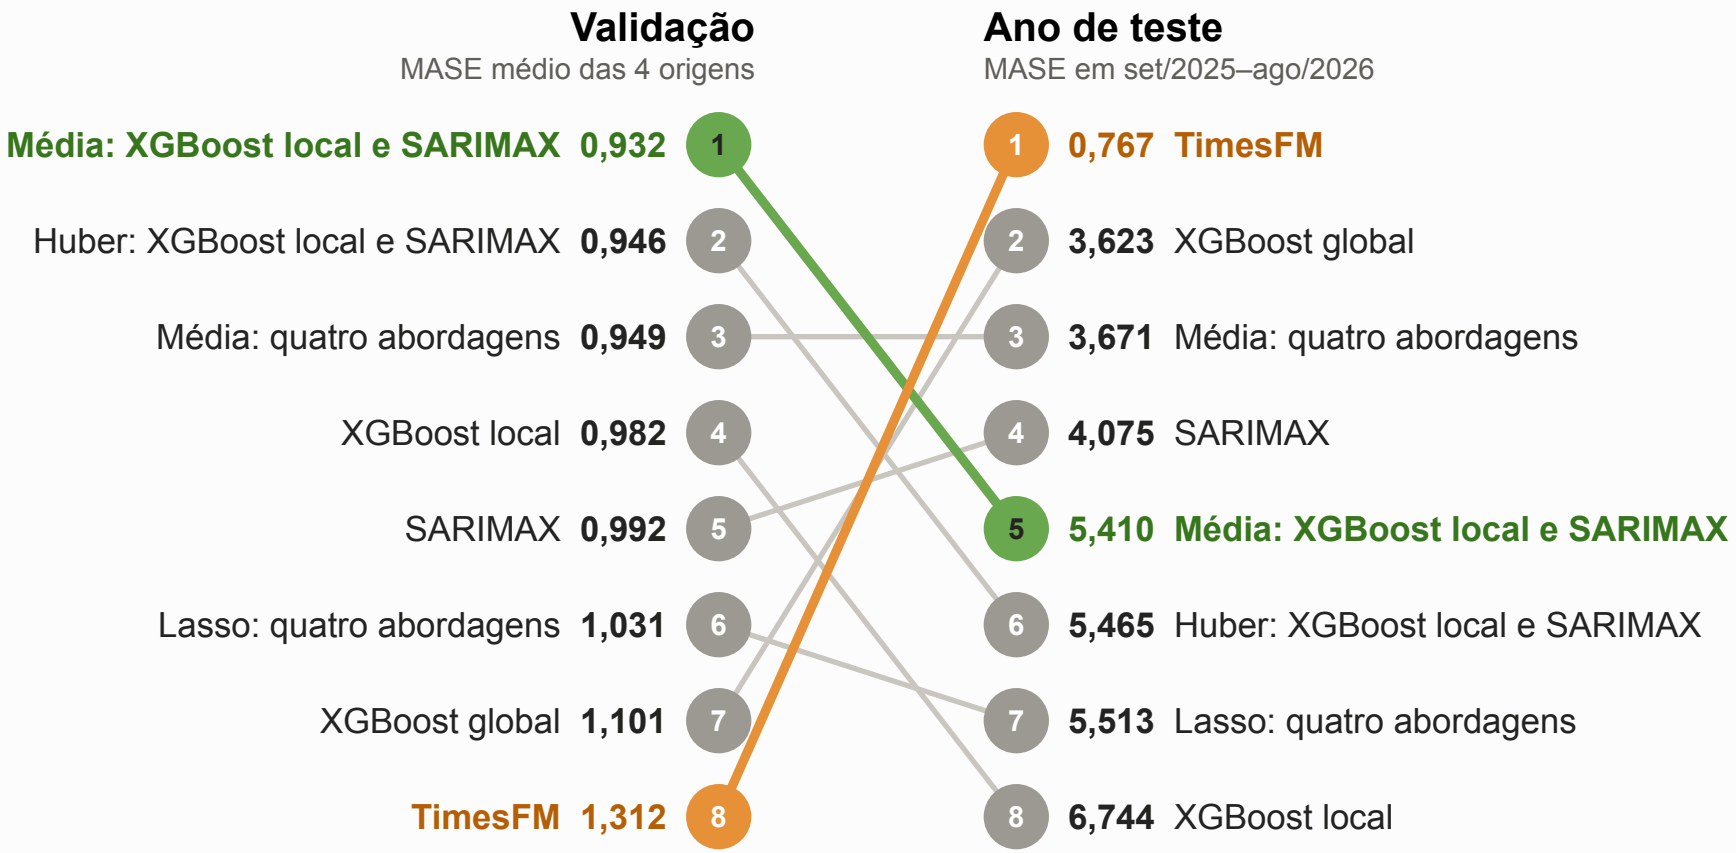
MASE do ingênuo sazonal na janela de 2024-08 (+39,6%): a dificuldade concentrou-se na aceleração

0,808 → 2,829

TimesFM: melhor isolado no crescimento moderado, pior no acelerado

Vencedores: janelas curtas, alvo como crescimento anual e atributos de crescimento recente

No ano de teste, a classificação se inverteu



Posição entre os oito modelos pelo MASE sazonal. Referências fora da posição: ingênuo sazonal (1,786 na validação; 1,191 no teste). Fonte: Resultados originais da pesquisa (Tabelas 4 e 5)

ρ = −0,48

correlação de Spearman entre as posições na validação e no teste

0,767

MASE do TimesFM: único modelo abaixo do ingênuo sazonal (1,191)

+4,1%

crescimento no ano de teste (9.210.150 chegadas), após +39,6% na validação

Modelos treinados superestimaram o ano em 27% a 50%

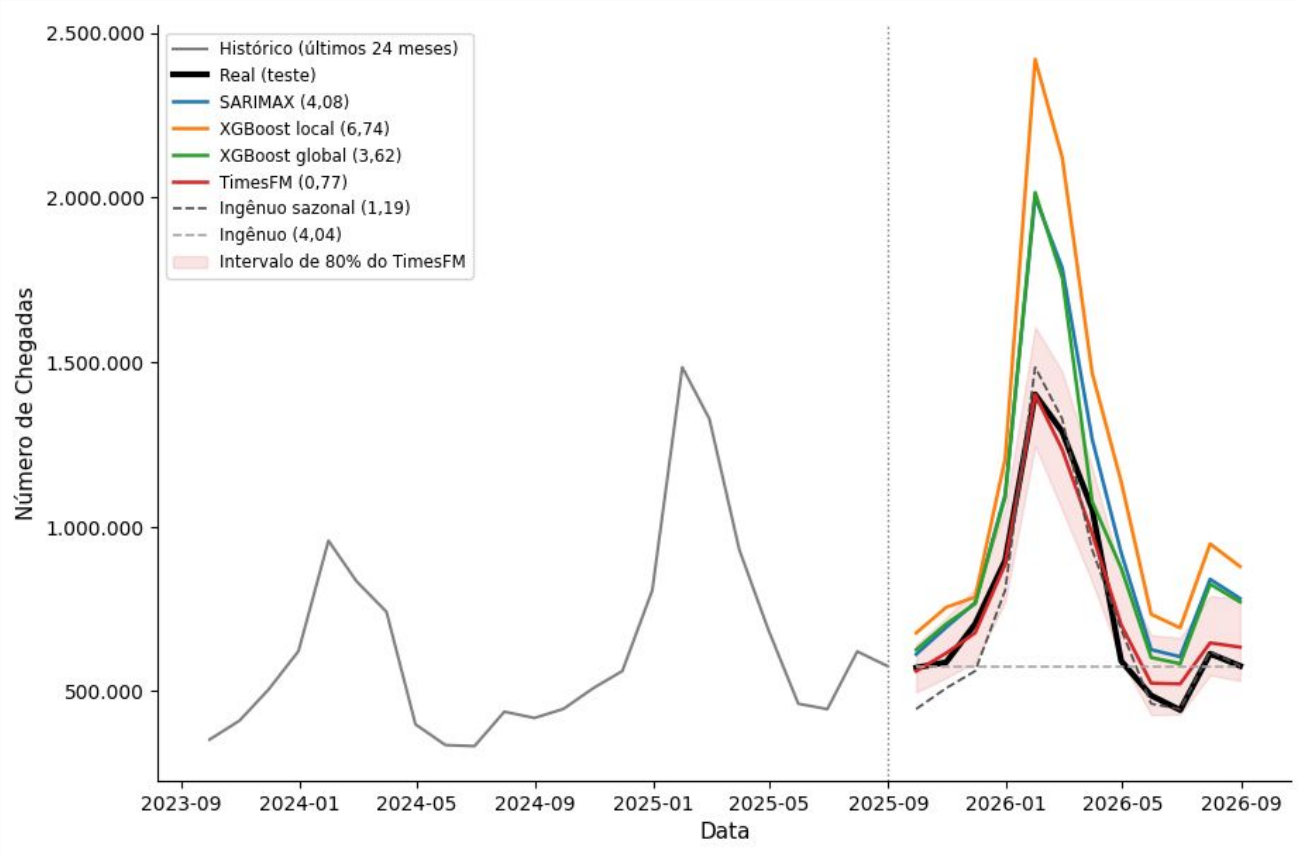
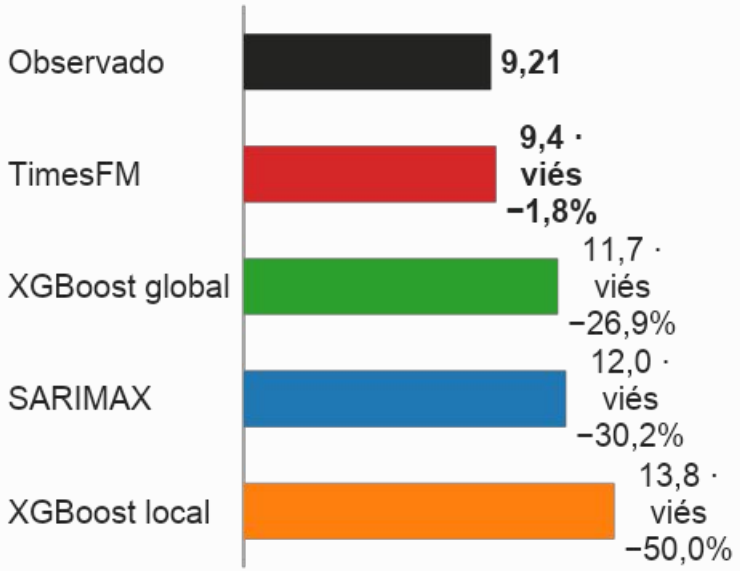


Figura 6A. Previsões do ano de teste das abordagens isoladas, com o intervalo de 80% do TimesFM sombreado; a linha preta é o observado. Fonte: Resultados originais da pesquisa

Total previsto para o ano de teste (milhões de chegadas)



92% dos meses de teste dentro do intervalo de 80% do TimesFM

O erro dos modelos espelha o erro da meta oficial

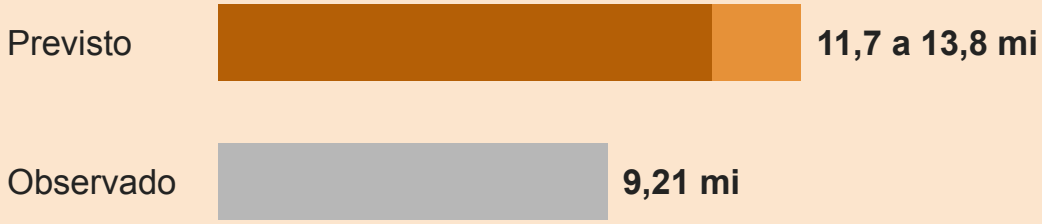
Meta oficial para 2025 (PNT 2024–2027)



subestimou

realizado 34,6% acima da meta: extrapolou o regime anterior

Estimativas dos modelos treinados



superestimaram

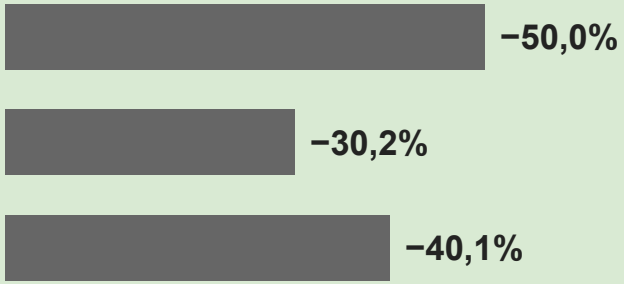
em 27% a 50%: extrapolaram o salto de 2025

Nos dois casos, falhou a hipótese implícita de **continuidade do regime**

Combinações não corrigiram o viés compartilhado

Combinar reduz variância, não viés

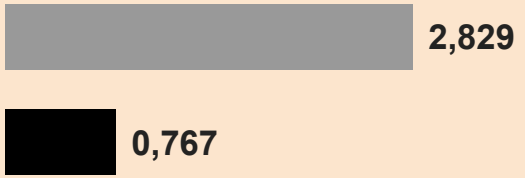
Viés no ano de teste (negativo = superestimação)



As duas melhores na validação eram justamente as de maior viés de crescimento

Histórico longo ancorou no nível sazonal

MASE do **TimesFM** (sem pandemia e sem transformação)



Acertou o ano estável, mas falhou no ano de aceleração

A superioridade de métodos puramente de séries temporais (Athanasopoulos et al., 2011) **depende de o regime avaliado se assemelhar ao do período de seleção**

Ressalvas que delimitam os resultados

Sobre o teste e o TimesFM

Uma única janela de teste
12 meses não bastam para uma ordenação estável entre abordagens

Possível sobreposição do pré-treino
o TimesFM 3.0 saiu após o início do ano de teste; seu pré-treino pode conter estatísticas de turismo do período

Licença restrita
pesos do TimesFM limitados a uso não comercial

Sobre o desenho do estudo

Regimes confundidos com períodos
janelas estáveis eram todas pré-pandêmicas; a acelerada, pós-pandêmica

Sem variáveis explicativas
câmbio e conectividade aérea poderiam antecipar mudanças de regime

Desempenho do TimesFM lido como **limite superior**

Conclusões

01 A seleção por validação em múltiplas origens **não garantiu bom desempenho após a mudança de regime**: quem melhor acompanhou a aceleração de 2025 mais superestimou o ano seguinte

02 **Nenhum modelo treinado, isolado ou combinado, superou o ingênuo sazonal no teste**; o TimesFM, último na validação, teve o menor erro

03 Para o planejamento do setor, considerar o **desempenho em regimes distintos e o viés direcional**, e não apenas o erro médio em janelas recentes

Trabalhos futuros

- Incorporar variáveis explicativas da demanda
- Ampliar o número de anos de teste
- Avaliar mecanismos de detecção de mudanças de regime

Obrigado!

Gabriel Moraes Magalhães · gabrielmoraesmagalhaes@gmail.com

github.com/Gbrlmoraes/brazil_tourism_forecasting_benchmark

MBA USP ESALQ

Apêndice

Material de apoio para a arguição

Apêndice · MASE sazonal por origem de validação

Abordagem	2017-08 +2,8%	2018-08 −3,7%	2023-08 +15,7%	2024-08 +39,6%	Média	Pior
Média: XGBoost local e SARIMAX	0,691	1,014	0,957	**1,066**	**0,932**	**1,066**
Huber: XGBoost local e SARIMAX	**0,646**	0,988	0,987	1,165	0,946	1,165
Média: quatro abordagens	0,764	0,797	0,856	1,377	0,949	1,377
XGBoost local	0,756	1,063	0,932	1,179	0,982	1,179
SARIMAX	0,723	0,970	1,017	1,258	0,992	1,258
Lasso: quatro abordagens	0,753	0,927	0,939	1,503	1,031	1,503
XGBoost global	1,308	**0,591**	0,943	1,563	1,101	1,563
TimesFM	0,912	0,701	**0,808**	2,829	1,312	2,829
Ingênuo sazonal	0,680	0,977	1,463	4,024	1,786	4,024
Ingênuo	3,325	2,442	3,393	6,148	3,827	6,148

Em negrito, o menor valor de cada coluna. SARIMAX(0,1,2)(0,1,1)[12] com logaritmo, últimos quatro anos e indicadores de pandemia e recuperação; XGBoost local com diferença sazonal do logaritmo, últimos quatro anos, estratégia recursiva e ajuste bayesiano; XGBoost global com últimos seis anos; TimesFM com histórico completo sem 2020–2022, covariáveis de calendário e média simétrica. Fonte: Resultados originais da pesquisa (Tabela 4)

Apêndice · Métricas no ano de teste (set/2025–ago/2026)

Abordagem	MASE	RMSE	MAPE (%)	R^2	Viés (%)	MASE na validação
TimesFM	0,767	53.538	6,9	0,969	−1,8	1,312
Ingênuo sazonal	1,191	83.669	9,1	0,925	3,9	1,786
XGBoost global	3,623	266.020	26,1	0,243	−26,9	1,101
Média: quatro abordagens	3,671	256.005	26,8	0,299	−27,2	0,949
Ingênuo	4,036	360.829	22,8	−0,392	24,9	3,827
SARIMAX	4,075	282.245	29,3	0,148	−30,2	0,992
Média: XGBoost local e SARIMAX	5,410	376.613	38,6	−0,516	−40,1	0,932
Huber: XGBoost local e SARIMAX	5,465	384.430	38,9	−0,580	−40,5	0,946
Lasso: quatro abordagens	5,513	394.109	39,1	−0,661	−40,9	1,031
XGBoost local	6,744	471.339	48,0	−1,375	−50,0	0,982

Viés = $(\Sigma y - \Sigma \hat{y})/\Sigma y \times 100$; valores negativos indicam superestimação do ano. Correlação de Spearman entre as classificações de validação e de teste: −0,48. Fonte: Resultados originais da pesquisa (Tabela 5)

Apêndice · Destaques da seleção por abordagem

SARIMAX

- 5.964 de 6.048 configurações convergiram; 1.056 superaram o ingênuo sazonal
- d = 1 e D = 1: menores quantis de 5% do MASE (1,312 sem transformação; 1,380 com estacionarização)
- Selecionado: (0,1,2)(0,1,1)[12], log, últimos 4 anos, pandemia e recuperação → 0,992

ML local

- 639 configurações superaram o ingênuo sazonal
- 13 das 15 melhores: diferença sazonal do log + estratégia recursiva
- Optuna reduziu o MASE do XGBoost (4 anos) de 1,188 para 0,982

ML global

- Painel de 21 séries: via, região de destino e 3 maiores origens
- Total = soma das componentes e da série remanescente
- Não superou a abordagem local (1,101)

TimesFM 3.0

- Configuração padrão: 178ª de 360 (1,715)
- Melhor contexto: histórico completo sem a pandemia, covariáveis de calendário e média simétrica → 1,312
- Melhor isolado na janela moderada (0,808); pior na acelerada (2,829)

Apêndice · Imputação do período pandêmico

Método	MAPE de reconstrução (%)	Razão de variâncias	MAPE a jusante (%)	MAPE na validação (%)
ARIMA progressivo	26,75	0,526	19,60	30,52
Estacionarização automática + ARIMA	23,52	0,505	20,55	29,51
STL + PCHIP	64,03	1,316	20,84	26,95
Combinação de ARIMA	24,91	0,451	21,63	29,93
Interpolação linear	64,72	0,471	22,75	29,06
ARIMA regressivo	40,24	0,557	25,62	29,94
Spline cúbica	222,13	7,850	43,99	25,95
Apenas pós-pandemia, sem imputação	–	–	–	**22,42**

Desempenho médio nas 13 janelas simuladas e erro na previsão do ano de validação após imputar a lacuna real. Razão de variâncias igual a 1 indica reconstrução com a variabilidade original. O ARIMA ajustado com os valores reais da pandemia obteve MAPE de 26,07% na validação. Fonte: Resultados originais da pesquisa (Tabela 3)

Apêndice · Composição das chegadas

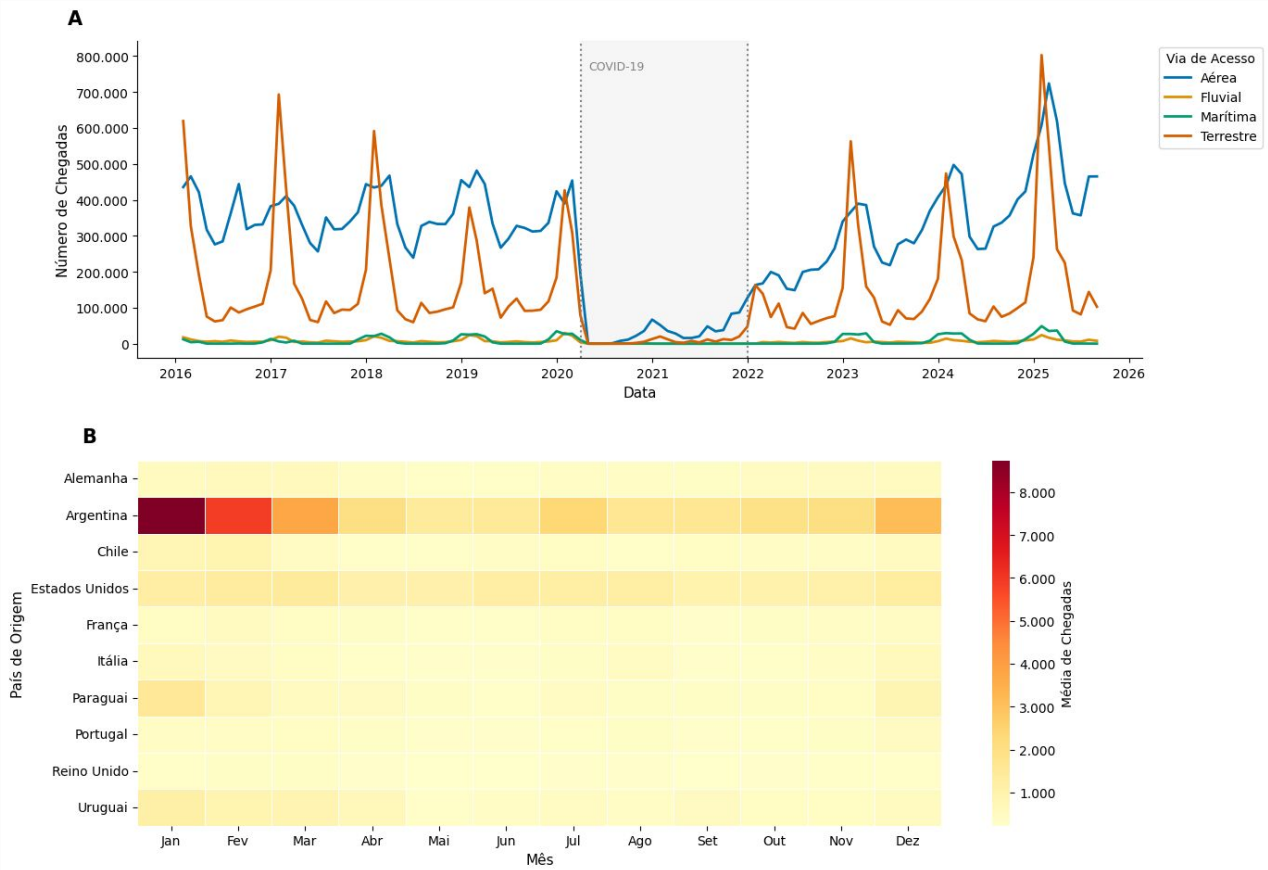


Figura 2. A) Chegadas mensais por via de acesso, 2016–2025; B) Média de chegadas por país de origem e mês, 1989–2025. Fonte: Resultados originais da pesquisa

Via de acesso
aérea 66,5% · terrestre 30,8% · marítima e fluvial 2,6%

Região de entrada
Sudeste 56,2% · Sul 31,9%

UF de entrada
SP 35,9% · RJ 19,8% · RS 16,2% · PR 12,5%

Origem
Argentina 29,5% · Estados Unidos 11,2%

Blocos
LATAM 53,7% · Europa 22,5% · Anglo-América 15,4%

Apêndice · Decomposição STL da série (2000–2025)

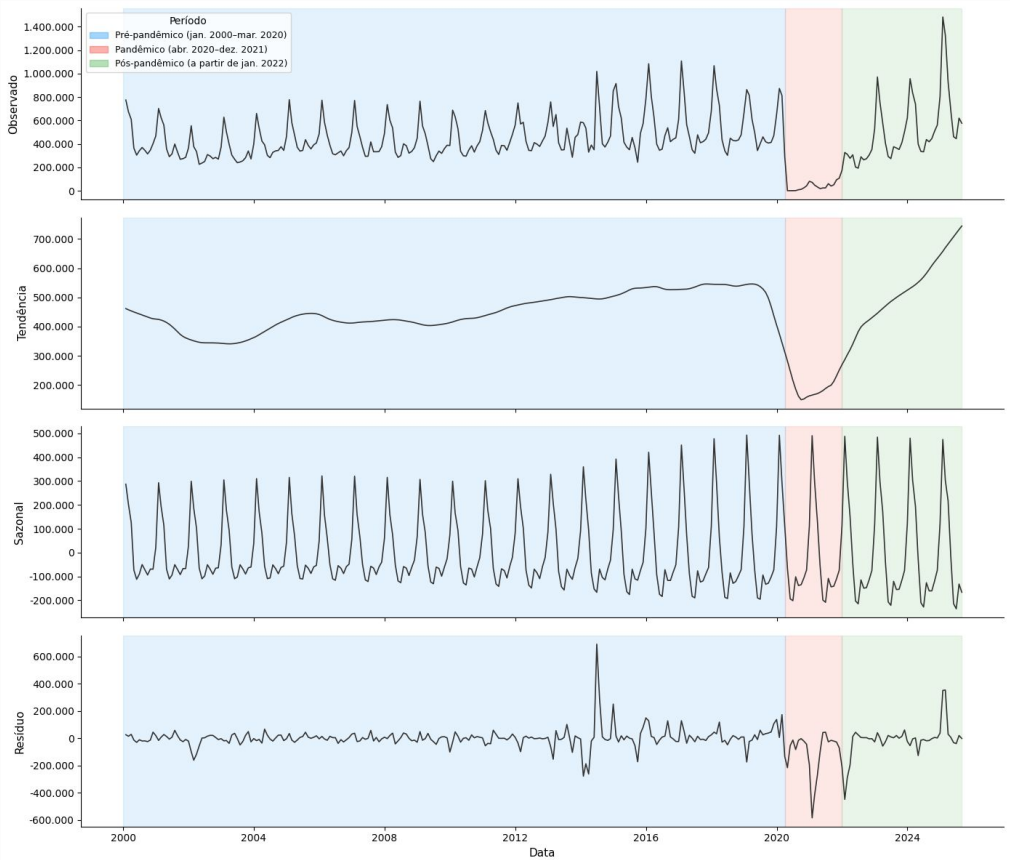


Figura 3. Decomposição STL robusta (período 12, janela sazonal 13). Fonte: Resultados originais da pesquisa

- Sazonalidade anual dominante, com pico em janeiro
- Força sazonal crescente após a pandemia (0,767 → 0,936)
- Tendência positiva, mas não monotônica: R^2 da tendência linear de 0,009 no período completo
- Box-Cox não eliminou a heterocedasticidade recente (teste de White, p = 0,001)