Mudança de regime compromete a seleção de modelos de previsão do turismo internacional brasileiro

Gabriel Moraes Magalhães[1]*; Édipo Menezes Da Silva[2]

[1]* Tecnólogo em Data Science. E-mail: gabrielmoraesmagalhaes@gmail.com
[2] Doutorando em Estatística Agrícola e Experimentação. E-mail: ediposvm01@gmail.com

Mudança de regime compromete a seleção de modelos de previsão do turismo internacional brasileiro

Resumo

O turismo internacional é relevante para a economia brasileira, e o planejamento do setor depende de previsões de demanda. Em 2025, as chegadas de turistas estrangeiros cresceram muito acima do previsto. O objetivo deste trabalho foi comparar abordagens estatísticas, de aprendizado de máquina e um modelo fundacional na previsão mensal, com 12 meses de antecedência, das chegadas de turistas internacionais ao Brasil, e verificar se a seleção de modelos por validação se sustentou após uma mudança de regime. Utilizou-se a série do Ministério do Turismo de janeiro de 1989 a agosto de 2026. Foram avaliados modelos SARIMAX, regressores lineares e de “gradient boosting” treinados na série total e em um painel de séries desagregadas, o modelo fundacional TimesFM sem treinamento específico e combinações desses modelos. A seleção empregou quatro origens de validação e o erro absoluto médio escalonado sazonal, e o período de setembro de 2025 a agosto de 2026 foi reservado como teste. Na validação, a média entre XGBoost e SARIMAX obteve o menor erro escalonado (0,932), e o TimesFM ficou em último lugar entre os modelos (1,312). No teste, as chegadas cresceram 4,1%, após alta de 39,6% no ano anterior; o TimesFM foi o único modelo a superar o ingênuo sazonal (0,767 contra 1,191), e os modelos treinados superestimaram o ano em 27% a 50%. A correlação entre as classificações de validação e de teste foi de −0,48. A seleção por validação recompensou a extrapolação do crescimento recente e perdeu validade com a mudança de regime.
Palavras-chave: séries temporais; MASE sazonal; XGBoost; TimesFM; validação temporal.

Introdução

O turismo ocupa posição de destaque na economia brasileira. Segundo relatório do World Travel & Tourism Council [WTTC], o Brasil foi o sétimo país que mais gerou empregos no setor, com previsão de 8,21 milhões de postos em 2025, e o 12º em contribuição do turismo para o Produto Interno Bruto [PIB], estimada em US$ 167,6 bilhões (Ministério do Turismo [MTUR], 2025). Decisões de infraestrutura, de promoção internacional e de metas de políticas públicas dependem de estimativas da demanda futura, e erros nessas estimativas resultam tanto em capacidade ociosa quanto em saturação de destinos.

O ano de 2025 ilustrou a dificuldade dessa tarefa. O país recebeu 9.287.196 turistas estrangeiros, 37,1% a mais que em 2024, e superou em 34,6% a meta de 6,9 milhões de chegadas prevista no Plano Nacional de Turismo [PNT] 2024–2027 (Agência Brasil, 2026). A realização superou a projeção oficial em mais de um terço. Esse salto ocorreu poucos anos após o colapso provocado pela pandemia de COVID-19, de modo que, em seis anos, a série acumulou uma queda abrupta, uma recuperação e uma aceleração sem precedentes, o que desafia métodos baseados na extrapolação do passado.

Na literatura de previsão da demanda turística, a competição conduzida por Athanasopoulos et al. (2011) mostrou que abordagens puramente de séries temporais foram mais precisas do que modelos com variáveis explicativas e adotou o erro absoluto médio

escalonado [MASE] como medida de comparação entre séries de escalas distintas. Desde então, o repertório disponível se ampliou com modelos de aprendizado de máquina baseados em atributos defasados (Joseph e Tackes, 2024) e com modelos fundacionais pré-treinados em grandes coleções de séries reais e sintéticas, capazes de prever séries novas sem treinamento específico (Das et al., 2024).

Independentemente da família de modelos, a configuração final costuma ser escolhida pelo desempenho em janelas de validação anteriores ao período de uso. Em séries não estacionárias, essa escolha só é confiável se as janelas de validação forem representativas do período a ser previsto (Joseph e Tackes, 2024). Quando há mudança de regime entre a validação e o uso, a configuração que melhor acompanhou o passado recente pode ser justamente a que mais erra, risco raramente medido em estudos comparativos que reportam o desempenho em um único período de teste.

O objetivo deste trabalho foi comparar modelos autorregressivos integrados de médias móveis sazonais com regressores exógenos [SARIMAX], modelos de aprendizado de máquina locais e globais, o modelo fundacional TimesFM e combinações desses modelos na previsão das chegadas mensais de turistas internacionais ao Brasil com 12 meses de antecedência, e avaliar se a classificação obtida por validação em múltiplas origens se manteve em um ano de teste posterior à mudança de regime de 2025.

Material e Métodos

Esta pesquisa caracteriza-se como um estudo quantitativo aplicado, de natureza experimental, baseado em dados secundários de acesso público. O processamento foi conduzido em Python, por meio de notebooks Jupyter executados em ambiente local, e todos os experimentos foram registrados na plataforma MLflow. O repositório com os códigos desenvolvidos ao longo da pesquisa está disponível no GitHub, cujo link consta no apêndice. As funções de testes estatísticos, de transformação da variável-alvo e de engenharia de atributos foram adaptadas do repositório que acompanha Joseph e Tackes (2024).

Base de dados e preparação

Os dados foram obtidos no Portal de Dados Abertos do Ministério do Turismo (MTUR, 2026), em 38 arquivos no formato “Comma-Separated Values” [CSV] com as estimativas mensais de chegadas por via de acesso, unidade federativa de entrada e país de residência, de janeiro de 1989 a agosto de 2026. Como os nomes das colunas mudaram

ao longo dos anos, a unificação utilizou um mapeamento de nomenclaturas que interrompe o processamento diante de colunas desconhecidas, e cada ano foi lido de um único arquivo, para evitar a dupla contagem dos arquivos acumulados do ano corrente. O conjunto consolidado soma 995.126 registros.

Os registros sem valor de chegadas (0,99% do total) foram removidos. As categorias textuais apresentavam caracteres corrompidos em arquivos antigos e grafias distintas para a mesma categoria; a padronização usou uma chave insensível a acentos que falha explicitamente diante de valores não mapeados, de modo que nenhuma categoria nova fosse descartada sem aviso. Foram derivadas a região de destino, a partir da unidade federativa, e a subdivisão cultural de origem, que agrupou os 209 países em oito blocos: LATAM, Europa Ocidental e Oriental, Anglo-América, Ásia-Pacífico [APAC], países nórdicos e bálticos, África Subsaariana, Oriente Médio e Norte da África [MENA] e Outros. A variável resposta foi o total mensal de chegadas, agregado sobre todas as vias, origens e destinos, com 452 observações.

Partição temporal

A série foi dividida cronologicamente em três blocos consecutivos: treino, de janeiro de 1989 a agosto de 2024 (428 meses); validação, de setembro de 2024 a agosto de 2025; e teste, de setembro de 2025 a agosto de 2026. As datas de corte foram derivadas dos próprios dados, e duas verificações garantiram a ausência de meses faltantes e a completude do último mês publicado. A análise exploratória, a engenharia de atributos e toda a seleção de modelos utilizaram apenas treino e validação, e o conjunto de teste foi lido uma única vez, na avaliação final (Figura 1).

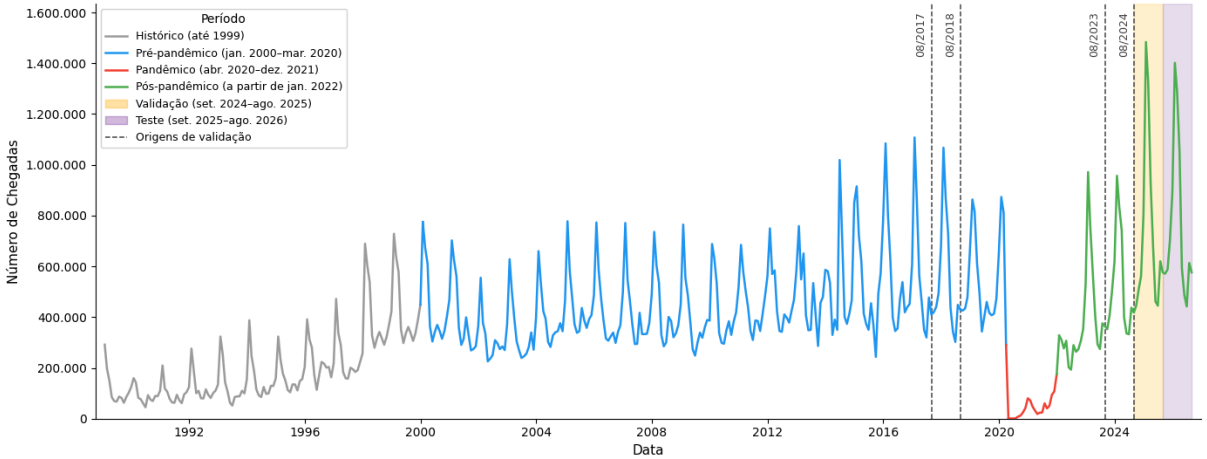


Figura 1. Chegadas mensais de turistas internacionais ao Brasil de jan. 1989 a ago. 2026, com os períodos analíticos, as quatro origens de validação e o ano de teste
Fonte: Dados originais da pesquisa

Nota: Períodos: histórico (até 1999), pré-pandêmico (jan. 2000–mar. 2020), pandêmico (abr. 2020–dez. 2021) e pós-pandêmico (a partir de jan. 2022)

Análise exploratória

A série mensal foi segmentada em quatro períodos analíticos: histórico (anterior a 2000), pré-pandêmico (janeiro de 2000 a março de 2020), pandêmico (abril de 2020 a dezembro de 2021) e pós-pandêmico (a partir de 2022). Em cada período, a tendência foi investigada por regressões linear e polinomial, pelos testes de Kendall e de Mann-Kendall, este com pré-branqueamento em séries curtas, e pela versão sazonal do teste de Mann-Kendall com período 12. O caráter determinístico ou estocástico da tendência foi avaliado pela comparação do teste Dickey-Fuller Aumentado [ADF] com constante e com constante e tendência.

O tipo de decomposição foi diagnosticado pela correlação entre a média e o desvio-padrão anuais, e a sazonalidade, pela decomposição sazonal e de tendência por regressão local (“Seasonal-Trend decomposition using Loess” [STL]) robusta, com período 12 e janela sazonal 13, pela força sazonal, calculada como 1 - Var(resíduo)/Var(sazonal + resíduo), e pelo teste de máximos locais da função de autocorrelação [ACF] com banda de Bartlett. A estacionariedade foi verificada pela combinação dos testes ADF e Kwiatkowski-Phillips-Schmidt-Shin [KPSS] sobre a série em nível e diferenciada; a heterocedasticidade, pelo teste de White; e a intensidade da transformação de potência, pelo parâmetro λ da transformação de Box-Cox estimado pelo método de Guerrero (Joseph e Tackes, 2024).

Tratamento do período pandêmico

Sete métodos de imputação da quebra estrutural foram comparados: interpolação linear; decomposição STL com interpolação cúbica de Hermite por partes [PCHIP] da tendência; “spline” cúbica; modelo autorregressivo integrado de médias móveis [ARIMA] automático ajustado sobre os dados anteriores à lacuna; ARIMA automático ajustado sobre a série invertida posterior à lacuna; combinação ponderada desses dois modelos; e estacionarização automática seguida de ARIMA. Treze janelas pré-pandêmicas de 6 a 36 meses, entre 1995 e 2015, foram mascaradas e reconstruídas.

Cada método foi avaliado por métricas de reconstrução, a saber, erro absoluto médio [MAE], raiz do erro quadrático médio [RMSE], erro percentual absoluto médio [MAPE] e razão entre as variâncias imputada e observada, e por uma métrica a jusante: o MAPE de um ARIMA ajustado sobre a série imputada ao prever os 12 meses seguintes, em geometria

livre de vazamento. Os métodos foram, em seguida, aplicados à lacuna real (abril de 2020 a dezembro de 2021) e comparados na previsão do ano de validação.

Protocolo de validação e métricas

Uma única janela de validação pode premiar configurações ajustadas às particularidades daquele ano (Joseph e Tackes, 2024). Por isso, cada configuração foi treinada e avaliada em quatro origens de validação sem sobreposição, cada uma prevendo os 12 meses seguintes: duas anteriores à pandemia (agosto de 2017 e agosto de 2018) e as duas mais recentes (agosto de 2023 e agosto de 2024), sendo esta última correspondente ao conjunto de validação. Em cada origem, o modelo utilizou apenas o histórico disponível até aquele mês, a partir do qual foram reconstruídas as janelas de treino, as transformações e os atributos. A métrica de seleção foi o MASE sazonal, calculado conforme a eq. (1):

$$MASE = \frac{\frac{1}{h}\sum_{t=T+1}^{T+h}\left|y_t - \hat{y}_t\right|}{\frac{1}{|P|}\sum_{t\in P}\left|y_t - y_{t-12}\right|} \quad (1)$$

em que: y_t é o total de chegadas no mês t; $\hat{y}_t$ é a previsão; h = 12 é o horizonte; T é a origem; e P é o conjunto de meses do histórico até a origem cujos pares (t, t − 12) não tocam o intervalo de abril de 2020 a dezembro de 2022.

O escalonamento pelo erro do ingênuo sazonal no histórico torna comparáveis origens com níveis diferentes, e valores inferiores a 1 indicam erro menor que o da previsão “mesmo mês do ano anterior”. As configurações foram ordenadas pela média do MASE nas quatro origens, e o pior MASE entre as origens foi usado como indicador de estabilidade. Também foram registrados o RMSE, o MAPE, o coeficiente de determinação [R^2] e o viés da previsão, definido como $(\Sigma y - \Sigma\hat{y})/\Sigma y \times 100$ e positivo quando o ano foi subestimado. As referências foram o ingênuo, que repete o último mês observado, e o ingênuo sazonal, que repete o mesmo mês do ano anterior. Para comparar escolhas de modelagem sem depender de uma configuração isolada, foram construídos mapas de calor com o quantil de 5% do MASE médio de cada combinação de escolhas. As grades de configurações de cada abordagem estão sintetizadas na Tabela 1.

Tabela 1. Grades de configurações avaliadas por abordagem

Abordagem	Escolhas combinadas na grade	Configurações	Ajuste de hiperparâmetros
SARIMAX	144 ordens × 3 tratamentos do alvo × 14 seleções de treino	6.048	Máxima verossimilhança

Abordagem	Escolhas combinadas na grade	Configurações	Ajuste de hiperparâmetros
Aprendizado de máquina local	4 famílias × 4 tratamentos do alvo × 8 janelas × 2 tratamentos da pandemia × 2 estratégias × 6 conjuntos de atributos	2.880	Validação cruzada temporal (lineares) e Optuna, 40 tentativas (árvores)
Aprendizado de máquina global	4 famílias × 3 tratamentos do alvo × 3 janelas × 2 tratamentos da pandemia × 2 estratégias × 3 conjuntos de atributos	432	Validação cruzada temporal (lineares) e Optuna, 25 tentativas (árvores)
TimesFM	8 janelas de contexto × 3 tratamentos da pandemia × 3 tratamentos do alvo × 4 conjuntos de covariáveis × média simétrica	360	Sem treinamento
Combinações	7 métodos × 2 grupos de membros	13	Pesos estimados deixando uma origem de fora

Fonte: Dados originais da pesquisa
Nota: Nas grades de aprendizado de máquina e do TimesFM, a janela pós-pandêmica foi combinada apenas com a manutenção dos meses da pandemia, e as covariáveis da pandemia do TimesFM, apenas com a manutenção desses meses

Modelos SARIMAX

Os modelos SARIMAX foram ajustados com a biblioteca statsmodels. A grade cruzou 144 ordens, com $p, q \in \{0, 1, 2\}$, d, D, P, Q $\in \{0, 1\}$ e período sazonal $s = 12$; três tratamentos da variável-alvo, a saber, nenhum, logaritmo natural e uma estacionarização automática que remove a tendência linear, a sazonalidade e aplica Box-Cox somente quando os respectivos testes o indicam; e 14 seleções de dados de treino. As seleções compreenderam janelas dos últimos quatro a 14 anos com uma variável indicadora da pandemia (abril de 2020 a dezembro de 2021), com ou sem uma segunda indicadora para a recuperação (janeiro a junho de 2022), e janelas restritas ao período pós-pandêmico. As ordens de diferenciação foram buscadas, e não fixadas, para verificar se as transformações dispensavam a diferenciação. Os critérios de informação de Akaike [AIC] e bayesiano [BIC] foram registrados, mas não usados na classificação, pois só são comparáveis entre modelos com a mesma transformação e a mesma diferenciação.

Aprendizado de máquina local

Para os modelos de aprendizado de máquina, a série foi convertida em um problema de regressão supervisionada. As defasagens foram escolhidas pela função de

autocorrelação parcial [PACF] do período pré-pandêmico (1, 2, 12, 13, 24 e 36 meses) e complementadas por estatísticas móveis de 3, 6 e 12 meses, médias móveis do mesmo mês em anos anteriores, médias móveis exponenciais, taxas de crescimento mensal, termos de Fourier do mês, tempo decorrido e indicadores da pandemia e das defasagens que apontam para ela. Todo atributo derivado do alvo foi deslocado no mínimo pelo passo de previsão, e um teste de perturbação, no qual os valores posteriores a uma data de corte foram multiplicados por dez sem alterar nenhum atributo anterior, confirmou a ausência de vazamento.

A grade combinou quatro famílias de modelos (Ridge, Lasso, LightGBM e XGBoost); quatro tratamentos do alvo, os três do SARIMAX e a diferença sazonal do logaritmo; oito janelas de treino; duas formas de tratar a pandemia, mantendo os meses com seus indicadores ou removendo os anos de 2020 a 2022 da série; duas estratégias de múltiplos passos, a recursiva, que realimenta as previsões, e a direta com um único modelo cujos atributos são conhecidos 12 meses à frente; e seis conjuntos de atributos. A diferença sazonal do logaritmo e sua inversa foram definidas pela eq. (2):

$$z_t = ln\left(y_t\right) - ln\left(y_{t-12}\right); \quad \hat{y}_t = y_{t-12} \cdot exp\left(\hat{z}_t\right) \tag{2}$$

em que: z□ é a taxa de crescimento anual em escala logarítmica e ẑ□, sua previsão. Essa transformação permite a modelos de árvore prever níveis superiores ao máximo observado no treino, limitação conhecida desses modelos em séries com tendência (Joseph e Tackes, 2024).

As penalidades de Ridge e Lasso foram escolhidas por validação cruzada temporal com divisões sucessivas da série. Os modelos de árvore utilizaram taxa de aprendizado de 0,02, até 2.000 árvores e parada antecipada nos últimos 12 meses da janela de treino, nunca na janela de validação. A melhor configuração de cada combinação de família de árvore e janela de treino foi refinada por otimização bayesiana com a biblioteca Optuna, em 40 tentativas, tendo como objetivo o próprio MASE médio nas quatro origens.

Aprendizado de máquina global

Na abordagem global, um único modelo foi treinado sobre um painel de 21 séries: 19 componentes definidos por via de acesso (aérea e terrestre), região de destino e as três maiores subdivisões de origem (LATAM, Europa e Anglo-América), com média mínima de mil chegadas mensais, uma série remanescente que completa a soma e a série total. As componentes cobriram 86,2% das chegadas do treino. Cada série recebeu atributos

estáticos de identificação e uma transformação do alvo ajustada individualmente, e a previsão do total foi obtida pela soma das componentes e da série remanescente. A melhor configuração de cada combinação de família de árvore e janela foi refinada com Optuna em 25 tentativas.

Modelo fundacional TimesFM

O TimesFM (“Time Series Foundation Model”) é um “transformer” decodificador pré-treinado em um grande conjunto de séries reais e sintéticas, que prevê uma série nova sem ajuste de pesos (Das et al., 2024). Foi utilizada a versão 3.0 sobre a série total. Como não há pesos a ajustar, a grade variou o contexto fornecido ao modelo: a janela de histórico; o tratamento da pandemia, que podia ser mantida, removida ou mascarada como ausente; a transformação do alvo; as covariáveis de calendário e da pandemia; e a média simétrica de inferência, que também prevê a série com sinal invertido. Os quantis 0,1 e 0,9 foram usados para avaliar a cobertura do intervalo de 80%.

Combinações de previsões

As melhores configurações de cada abordagem foram combinadas pela média, pela mediana, pela média ponderada pelo inverso do MASE e por regressões de empilhamento (Huber, linear, Ridge e Lasso), sem intercepto e com pesos não negativos, exceto na regressão de Huber. Foram considerados dois grupos: as quatro abordagens e as duas melhores na validação. Os pesos foram estimados deixando uma origem de fora, de modo que nenhuma previsão foi avaliada nos meses utilizados para estimar seus pesos.

Avaliação no ano de teste

Cada abordagem selecionada foi reajustada com todo o histórico até agosto de 2025, após a verificação de que o código reproduzia as previsões de validação registradas com diferença relativa máxima inferior a 10^{-6}. Os pesos das combinações foram estimados apenas com as previsões de validação. As previsões do ano de teste foram congeladas por uma impressão digital criptográfica (SHA-256) antes da leitura do conjunto de teste, e a concordância entre as classificações de validação e de teste foi medida pela correlação de postos de Spearman.

Resultados e Discussão

Análise exploratória

A via aérea respondeu por 66,5% das chegadas acumuladas nos períodos de treino e validação, seguida pela via terrestre (30,8%), enquanto as vias marítima e fluvial somaram 2,6%. As entradas concentraram-se nas regiões Sudeste (56,2%) e Sul (31,9%), sobretudo em São Paulo (35,9%), Rio de Janeiro (19,8%), Rio Grande do Sul (16,2%) e Paraná (12,5%). Na origem, a Argentina liderou com 29,5%, seguida dos Estados Unidos (11,2%), o que se refletiu no predomínio do bloco LATAM (53,7%) sobre Europa (22,5%) e Anglo-América (15,4%). O cruzamento dessas dimensões evidenciou um fluxo terrestre de argentinos concentrado em janeiro, principal componente do pico de verão (Figura 2).

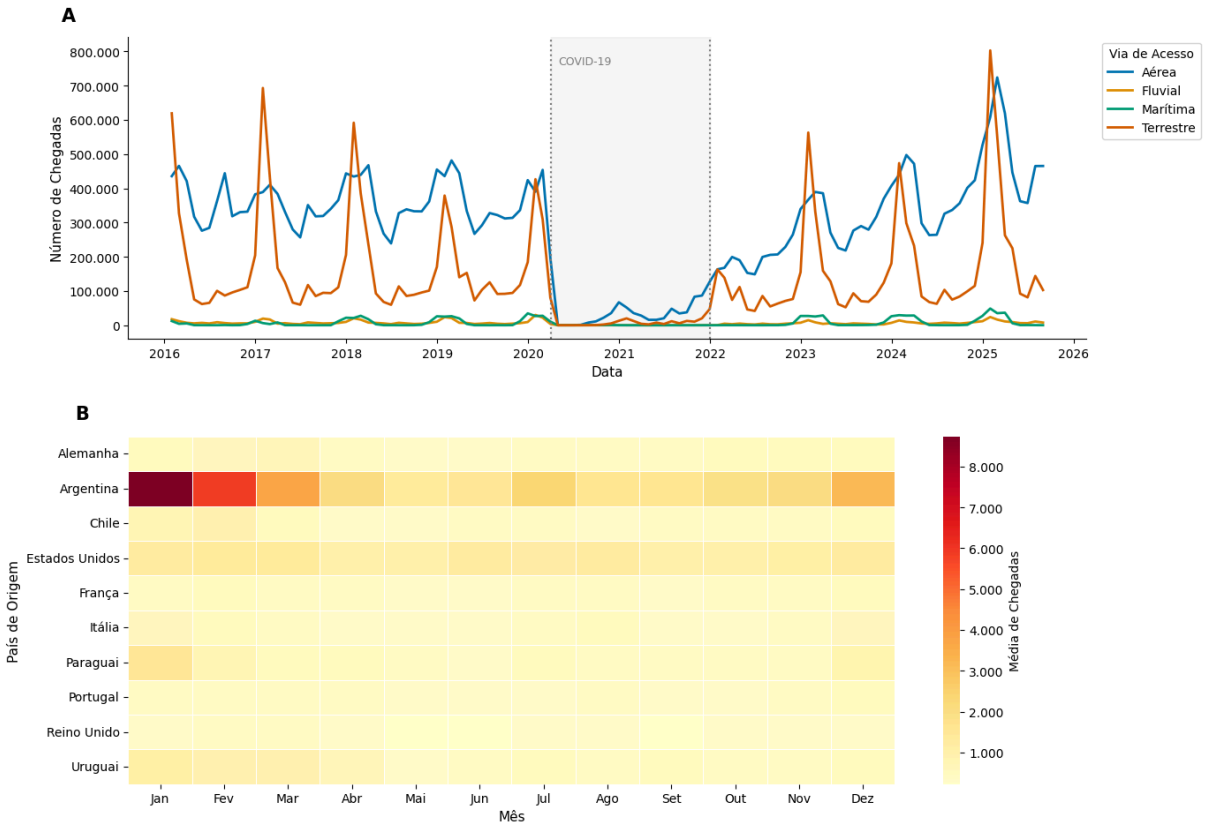


Figura 2. Chegadas mensais por via de acesso e média mensal de chegadas dos dez principais países de origem
Fonte: Resultados originais da pesquisa
Nota: A) Chegadas mensais por via de acesso, 2016–2025; B) Média de chegadas por país de origem e mês, 1989–2025

A série agregada apresentou tendência positiva pelos testes de Kendall e de Mann-Kendall sazonal em todos os períodos, mas não monotônica: o R^2 da tendência linear foi de apenas 0,009 no período completo. A comparação dos testes ADF indicou tendência

estocástica no período completo e no pré-pandêmico, o que favoreceu a diferenciação em vez de um termo determinístico. A correlação entre média e desvio-padrão anuais caracterizou comportamento multiplicativo nos períodos pré e pós-pandêmico, e a decomposição STL confirmou a dominância da sazonalidade anual, com pico em janeiro e força sazonal crescente após a pandemia (Tabela 2).

Tabela 2. Diagnósticos estruturais da série de chegadas e implicações para a modelagem

Diagnóstico	Pré-pandêmico	Pós-pandêmico	Implicação
Tendência (ADF com constante vs. com tendência)	Estocástica	Determinística (44 meses)	Diferenciação simples incluída na grade
Correlação média–desvio-padrão anual	0,897	0,992	Comportamento multiplicativo; logaritmo e Box-Cox testados
Força sazonal (STL)	0,767	0,936	Sazonalidade anual dominante; diferenciação sazonal
λ de Box-Cox (Guerrero)	−0,43	−0,04	Transformação tratada como hiperparâmetro
Estacionariedade (ADF e KPSS)	Após Diff(1) e Diff(12)	Após Diff(1) e Diff(12)	SARIMA(p, 1, q)(P, 1, Q)[12] como referência

Fonte: Resultados originais da pesquisa
Nota: Diff(1): diferenciação simples; Diff(12): diferenciação sazonal de período 12

A decomposição da série completa está apresentada na Figura 3. A série em nível foi não estacionária ou ambígua em todos os períodos, ao passo que a combinação de uma diferenciação simples e uma sazonal produziu veredito conjunto de estacionariedade, o que indicou SARIMA(p, 1, q)(P, 1, Q)[12] como especificação de referência. O λ de Box-Cox variou de −0,43 no pré-pandêmico a −0,04 no pós-pandêmico, e a transformação não eliminou a heterocedasticidade do período recente (teste de White com p = 0,001 após Box-Cox). Por essa instabilidade, a transformação do alvo foi tratada como hiperparâmetro da grade, e não fixada a priori.

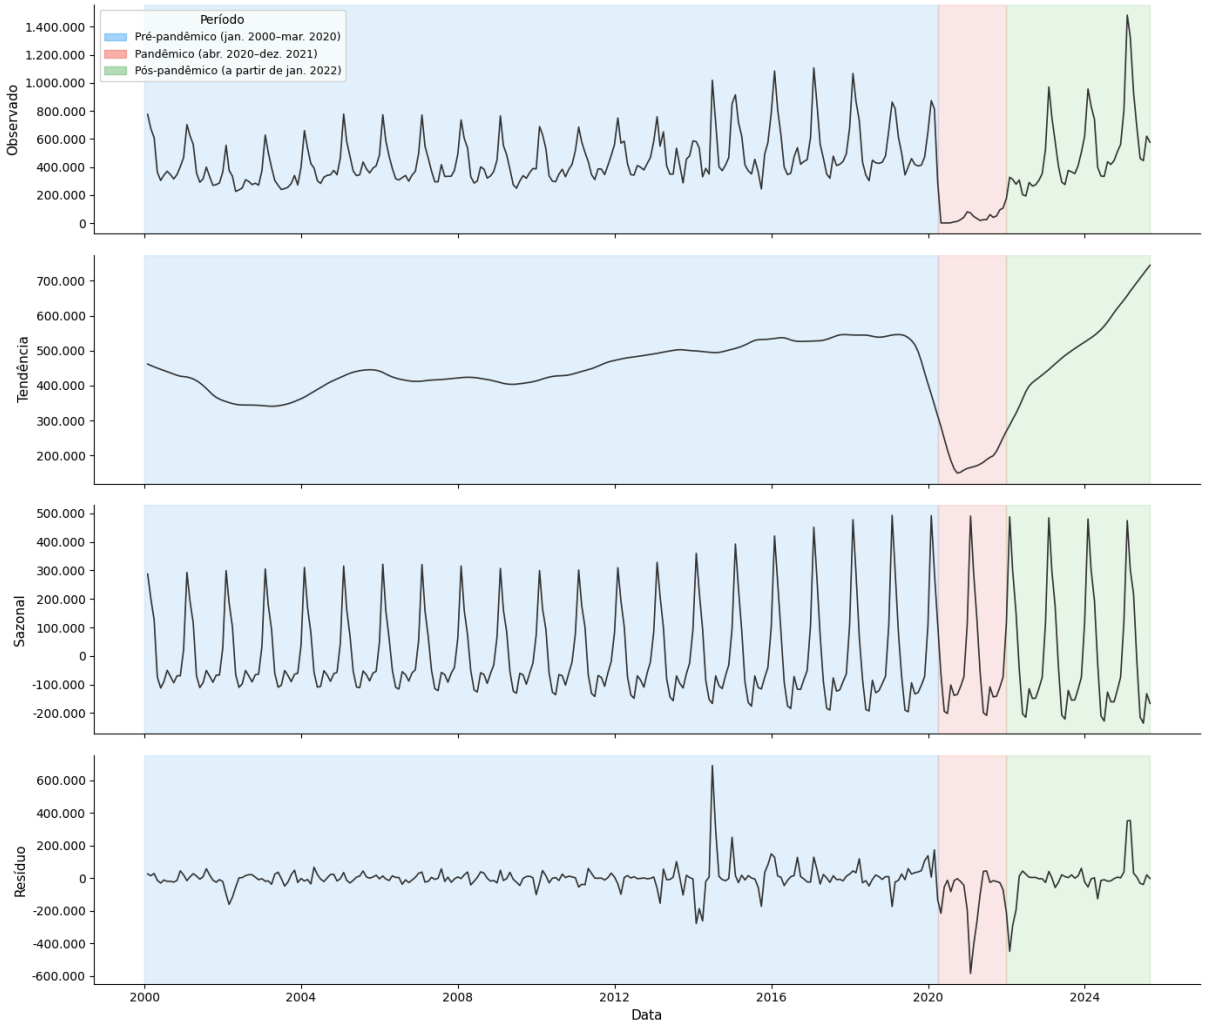


Figura 3. Decomposição STL da série mensal de chegadas de turistas internacionais ao Brasil (2000–2025)
Fonte: Resultados originais da pesquisa
Nota: Decomposição robusta com período 12 e janela sazonal 13

Tratamento do período pandêmico

Os métodos baseados em ARIMA obtiveram os menores erros de reconstrução nas janelas simuladas, enquanto a “spline” cúbica foi instável, com MAPE médio superior a 200% (Tabela 3). A ordenação por reconstrução, contudo, não coincidiu com a ordenação a jusante nem com o desempenho na lacuna real: ao imputar o intervalo pandêmico e prever o ano de validação, nenhum método superou o treino restrito ao período pós-pandêmico, que obteve MAPE de 22,42%, inferior até ao do modelo ajustado com os valores reais da pandemia (26,07%).

Tabela 3. Desempenho médio dos métodos de imputação nas 13 janelas simuladas e erro na previsão do ano de validação após a imputação da lacuna real

Método	MAPE de reconstrução (%)	Razão de variâncias	MAPE a jusante (%)	MAPE na validação (%)
ARIMA progressivo	26,75	0,526	19,60	30,52
Estacionarização automática + ARIMA	23,52	0,505	20,55	29,51
STL + PCHIP	64,03	1,316	20,84	26,95
Combinação de ARIMA	24,91	0,451	21,63	29,93
Interpolação linear	64,72	0,471	22,75	29,06
ARIMA regressivo	40,24	0,557	25,62	29,94
“Spline” cúbica	222,13	7,850	43,99	25,95
Apenas pós-pandemia, sem imputação	–	–	–	22,42

Fonte: Resultados originais da pesquisa
Nota: Razão de variâncias igual a 1 indica reconstrução com a variabilidade original. O ARIMA ajustado com os valores reais da pandemia obteve MAPE de 26,07% na validação

Esse resultado indica que a dificuldade do ano de validação não estava na lacuna, mas na aceleração das chegadas a partir do fim de 2024, que nenhum dos tratamentos antecipou (Figura 4). Como a qualidade da reconstrução não se traduziu em qualidade preditiva, a pandemia passou a ser tratada como escolha da grade de cada abordagem, por meio de indicadores exógenos, remoção dos anos afetados ou máscara de valores ausentes, em vez de uma imputação fixa.

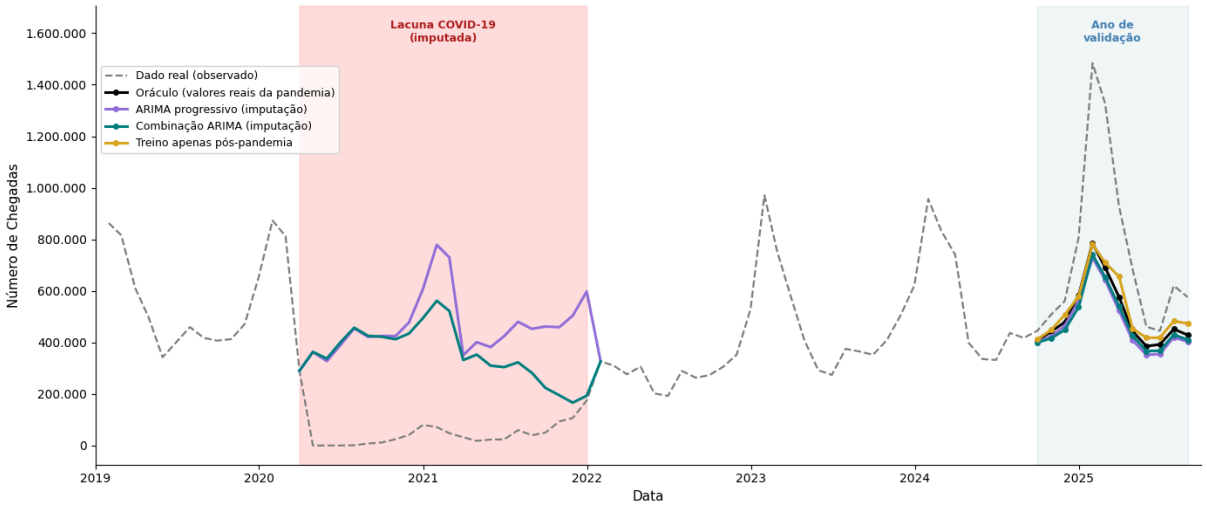


Figura 4. Imputações do intervalo pandêmico e previsões do ano de validação (set. 2024–ago. 2025) por tratamento do período pandêmico
Fonte: Resultados originais da pesquisa

Seleção de modelos na validação

As quatro janelas de validação apresentaram crescimentos anuais de 2,8%, −3,7%, 15,7% e 39,6%, respectivamente. A dificuldade concentrou-se na última janela, na qual o MASE do ingênuo sazonal atingiu 4,024. Todas as abordagens superaram o ingênuo sazonal na média, mas não em todas as origens: na janela de 2017, o ingênuo sazonal (0,680) foi melhor que qualquer abordagem isolada, o que é coerente com a dificuldade de superar referências simples em séries de turismo estáveis relatada por Athanasopoulos et al. (2011). O desempenho de cada configuração selecionada por origem está na Tabela 4.

Tabela 4. MASE sazonal das configurações selecionadas em cada origem de validação

Abordagem	2017-08	2018-08	2023-08	2024-08	Média	Pior
Média: XGBoost local e SARIMAX	0,691	1,014	0,957	1,066	0,932	1,066
Huber: XGBoost local e SARIMAX	0,646	0,988	0,987	1,165	0,946	1,165
Média: quatro abordagens	0,764	0,797	0,856	1,377	0,949	1,377
XGBoost local	0,756	1,063	0,932	1,179	0,982	1,179
SARIMAX	0,723	0,970	1,017	1,258	0,992	1,258
Lasso: quatro abordagens	0,753	0,927	0,939	1,503	1,031	1,503
XGBoost global	1,308	0,591	0,943	1,563	1,101	1,563
TimesFM	0,912	0,701	0,808	2,829	1,312	2,829
Ingênuo sazonal	0,680	0,977	1,463	4,024	1,786	4,024
Ingênuo	3,325	2,442	3,393	6,148	3,827	6,148

Fonte: Resultados originais da pesquisa
Nota: Crescimento anual das janelas: 2,8% (2017-08), −3,7% (2018-08), 15,7% (2023-08) e 39,6% (2024-08). SARIMAX(0,1,2)(0,1,1)[12] com logaritmo, últimos quatro anos e indicadores de pandemia e recuperação; XGBoost local com diferença sazonal do logaritmo, últimos quatro anos, estratégia recursiva e ajuste bayesiano; XGBoost global com últimos seis anos; TimesFM com histórico completo sem 2020–2022, covariáveis de calendário e média simétrica

Na grade do SARIMAX, 5.964 das 6.048 configurações convergiram em todas as origens, e 1.056 superaram o ingênuo sazonal. A combinação d = 1 e D = 1 produziu os menores valores do quantil de 5% do MASE, tanto sem transformação (1,312) quanto com estacionarização automática (1,380), o que confirmou a necessidade de diferenciação indicada pela análise exploratória. A configuração selecionada, SARIMAX(0,1,2)(0,1,1)[12] com logaritmo, janela dos últimos quatro anos e indicadores de pandemia e de recuperação, obteve MASE médio de 0,992.

Entre os modelos de aprendizado de máquina locais, 639 configurações superaram o ingênuo sazonal, e 13 das 15 melhores combinaram a diferença sazonal do logaritmo com a estratégia recursiva. O ajuste bayesiano reduziu o MASE médio do XGBoost com janela de quatro anos de 1,188 para 0,982, valor que o tornou a melhor abordagem isolada. A

abordagem global não superou a local (1,101), e o TimesFM, cuja configuração padrão ficou na 178ª posição entre 360 (1,715), atingiu 1,312 com o melhor contexto: histórico completo sem os anos da pandemia, covariáveis de calendário e média simétrica. O TimesFM foi a melhor abordagem isolada na janela de crescimento moderado (0,808), mas a pior na de crescimento acelerado (2,829).

As configurações vencedoras compartilharam janelas curtas, alvo expresso como crescimento anual e atributos de crescimento recente; a validação, portanto, premiou quem acompanhou a aceleração de 2025. A média entre XGBoost local e SARIMAX obteve o menor MASE médio (0,932) e o menor pior caso (1,066), resultado que, isoladamente, justificaria sua escolha para o uso (Figura 5).

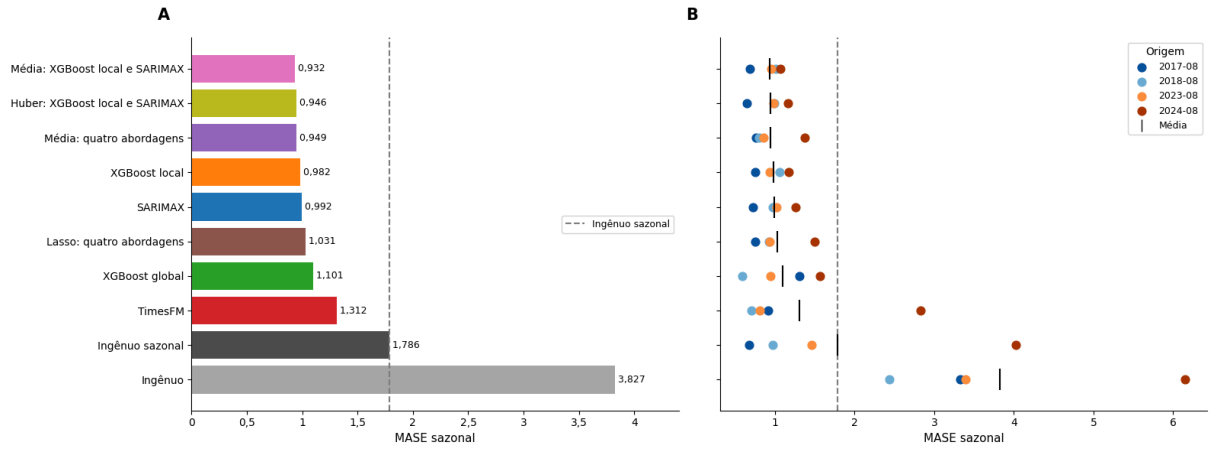


Figura 5. MASE sazonal médio por abordagem e MASE de cada origem de validação
Fonte: Resultados originais da pesquisa
Nota: A) Média das quatro origens, com a linha tracejada indicando o ingênuo sazonal; B) Cada ponto representa uma origem de validação

Avaliação no ano de teste

O ano de teste somou 9.210.150 chegadas, crescimento de 4,1% sobre o ano de validação, o que o caracterizou como estável. A ordenação da validação se inverteu: o TimesFM, último colocado entre os modelos na validação, obteve o menor erro no teste (MASE de 0,767 e MAPE de 6,9%) e foi o único modelo a superar o ingênuo sazonal (1,191), enquanto a combinação selecionada na validação ficou na quinta posição entre oito modelos (Tabela 5). O ingênuo, que apenas repete o último mês, superou o SARIMAX, o XGBoost local e todas as combinações com pesos estimados.

Tabela 5. Métricas das abordagens no ano de teste (set. 2025–ago. 2026)

Abordagem	MASE	RMSE	MAPE (%)	R^2	Viés (%)	MASE na validação
TimesFM	0,767	53.538	6,9	0,969	−1,8	1,312
Ingênuo sazonal	1,191	83.669	9,1	0,925	3,9	1,786
XGBoost global	3,623	266.020	26,1	0,243	−26,9	1,101
Média: quatro abordagens	3,671	256.005	26,8	0,299	−27,2	0,949
Ingênuo	4,036	360.829	22,8	−0,392	24,9	3,827
SARIMAX	4,075	282.245	29,3	0,148	−30,2	0,992
Média: XGBoost local e SARIMAX	5,410	376.613	38,6	−0,516	−40,1	0,932
Huber: XGBoost local e SARIMAX	5,465	384.430	38,9	−0,580	−40,5	0,946
Lasso: quatro abordagens	5,513	394.109	39,1	−0,661	−40,9	1,031
XGBoost local	6,744	471.339	48,0	−1,375	−50,0	0,982

Fonte: Resultados originais da pesquisa
Nota: Viés = (Σy − Σŷ)/Σy × 100; valores negativos indicam superestimação do ano

Os modelos treinados superestimaram o ano: o XGBoost local previu 13,8 milhões de chegadas, o SARIMAX, 12,0 milhões, e o XGBoost global, 11,7 milhões, contra 9,4 milhões do TimesFM (Figura 6). A correlação de postos entre as classificações de validação e de teste foi de −0,48, e o intervalo de 80% do TimesFM cobriu 92% dos meses de teste (Figura 7).

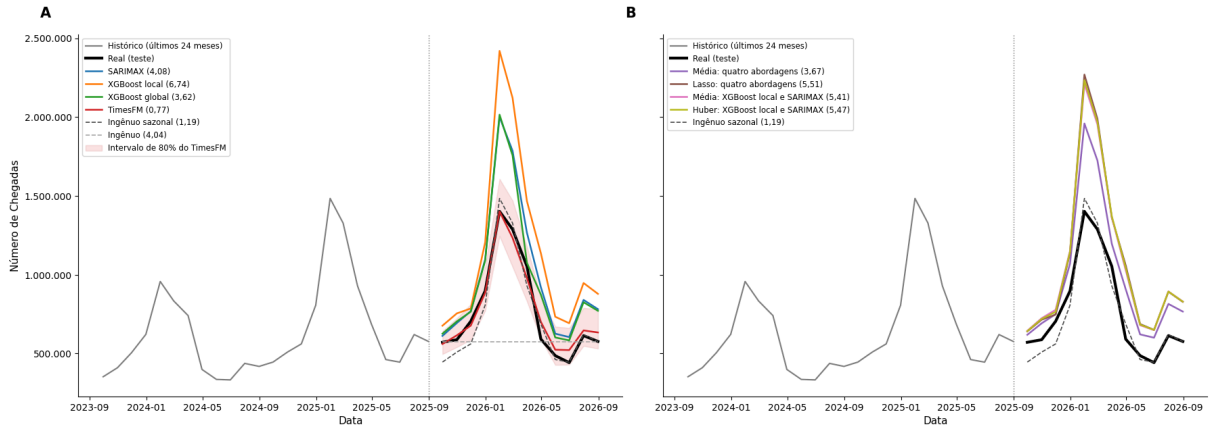


Figura 6. Previsões do ano de teste (set. 2025–ago. 2026) das abordagens isoladas e das combinações
Fonte: Resultados originais da pesquisa
Nota: A) Abordagens isoladas, com o intervalo de 80% do TimesFM sombreado; B) Combinações. A linha preta representa os valores observados

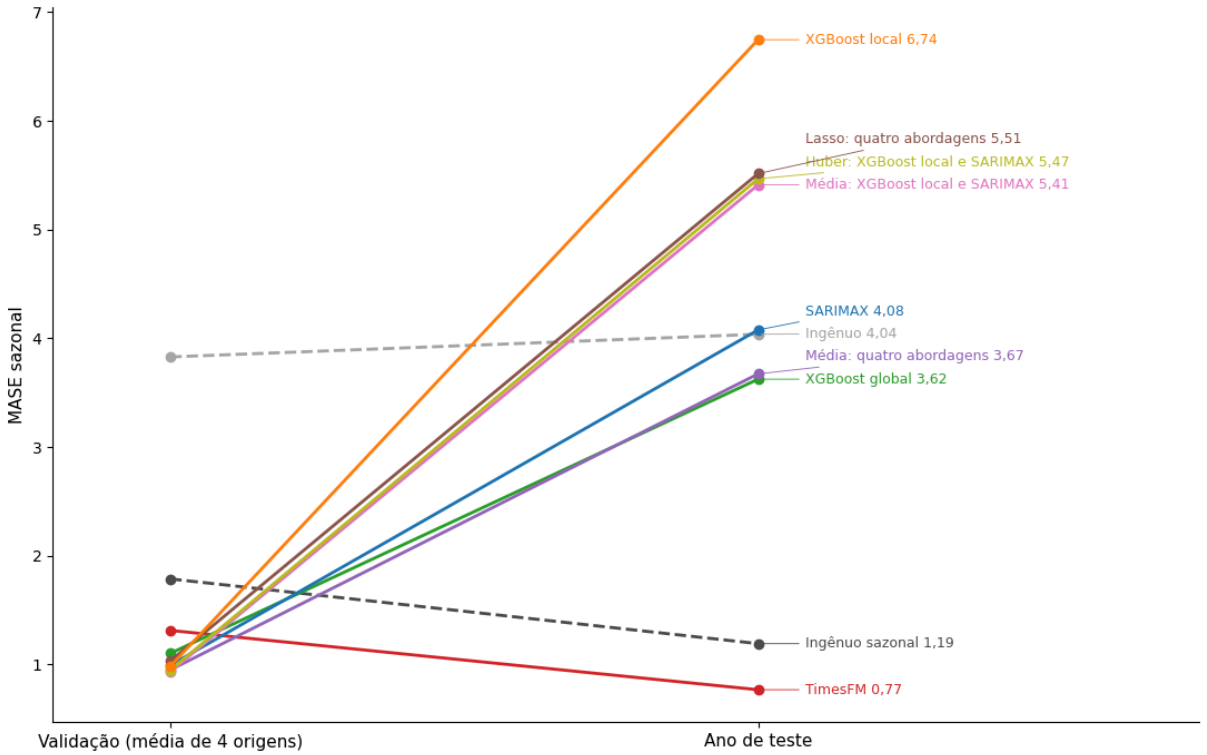


Figura 7. MASE sazonal de cada abordagem na validação, média das quatro origens, e no ano de teste
Fonte: Resultados originais da pesquisa

Implicações da mudança de regime

O protocolo de quatro origens foi desenhado para evitar que um único ano determinasse a escolha, mas as configurações que melhor se saíram na janela de crescimento acelerado foram as que aprenderam a projetar o crescimento recente. A estratégia recursiva propagou esse impulso ao longo dos 12 meses, e, quando a demanda se estabilizou em patamar elevado, os modelos treinados superestimaram o ano em 27% a 50%. Trata-se do erro simétrico ao da meta oficial: o PNT subestimou 2025 por extrapolar o regime anterior, e os modelos superestimaram o ano seguinte por extrapolar o salto de 2025. Em ambos os casos, a hipótese implícita de continuidade do regime falhou.

As combinações não protegeram contra esse erro. A média e o empilhamento reduzem a variância entre membros, mas não um viés compartilhado por eles, e o grupo das duas melhores abordagens na validação concentrou justamente os modelos com maior viés de crescimento. A abordagem que leu o histórico longo, sem a pandemia e sem transformação, permaneceu ancorada no nível sazonal e por isso acertou o ano estável, ainda que tenha falhado no ano de aceleração. A superioridade de métodos puramente de séries temporais observada por Athanasopoulos et al. (2011) depende, portanto, de que o regime do período avaliado se assemelhe ao do período de seleção.

Três ressalvas delimitam o resultado do TimesFM. O teste corresponde a uma única janela de 12 meses, insuficiente para estabelecer uma ordenação estável entre as abordagens. A versão 3.0 do modelo foi disponibilizada após o início do ano de teste, e seu conjunto de pré-treinamento pode conter estatísticas de turismo sobrepostas ao período avaliado, de modo que seu desempenho deve ser lido como limite superior. Por fim, os pesos utilizados têm licença restrita a uso não comercial. Somam-se a essas limitações a confusão entre regimes e períodos na validação, pois as janelas estáveis foram todas pré-pandêmicas e a de crescimento acelerado, pós-pandêmica, e a ausência de variáveis explicativas, como câmbio e conectividade aérea, que poderiam antecipar mudanças de regime.

Conclusão

A seleção de modelos por validação em múltiplas origens não garantiu bom desempenho após a mudança de regime das chegadas de turistas internacionais ao Brasil. As configurações que melhor acompanharam a aceleração de 2025 foram as que mais superestimaram o ano seguinte, e a classificação obtida na validação se inverteu no teste.

Nenhum modelo treinado, isolado ou combinado, superou a previsão ingênua sazonal no ano de teste. O modelo fundacional TimesFM, último colocado na validação, obteve o menor erro no teste, resultado que deve ser interpretado como limite superior em razão da possível sobreposição de seu pré-treinamento com o período avaliado.

Para o planejamento do setor, a escolha de modelos de previsão de chegadas internacionais deve considerar o desempenho em regimes distintos e o viés direcional das previsões, e não apenas o erro médio em janelas recentes. Recomenda-se, em trabalhos futuros, incorporar variáveis explicativas da demanda, ampliar o número de anos de teste e avaliar mecanismos de detecção de mudanças de regime.

Agradecimentos

Aos queridos amigos e família por todo o apoio em diversas partes da minha vida. Ao orientador, pelas contribuições e revisões ao longo do desenvolvimento deste trabalho.

Referências

Agência Brasil. 2026. Brasil recebeu em 2025 quase 10 milhões de turistas estrangeiros. Disponível em: <https://www.band.com.br/noticias/brasil-recebeu-em-2025-quase-10-milhoes-de-turistas-estrangeiros-202601070727>. Acesso em: 01 out. 2026.

Athanasopoulos, G.; Hyndman, R.J.; Song, H.; Wu, D.C. 2011. The tourism forecasting competition. International Journal of Forecasting 27(3): 822-844.

Das, A.; Kong, W.; Sen, R.; Zhou, Y. 2024. A decoder-only foundation model for time-series forecasting. In: International Conference on Machine Learning, 41., 2024, Viena, Áustria. Anais... p. 10148-10167

Joseph, M.; Tackes, J. 2024. Modern time series forecasting with Python. 2ed. Packt Publishing, Birmingham, Reino Unido

Ministério do Turismo [MTUR]. 2025. Brasil está entre as 10 maiores potências globais do turismo em geração de empregos, aponta WTTC. Disponível em: <https://www.gov.br/turismo/pt-br/assuntos/noticias/brasil-esta-entre-as-10-maiores-potencias-globais-do-turismo-em-geracao-de-empregos-aponta-wttc>. Acesso em: 01 out. 2026.

Ministério do Turismo [MTUR]. 2026. Estimativas de chegadas de turistas internacionais ao Brasil. Disponível em: <https://dados.gov.br/dados/conjuntos-dados/estimativas-de-chegadas-de-turistas-internacionais-ao-brasil>. Acesso em: 01 out. 2026.

Apêndice . Repositório e notebooks do estudo

O código-fonte do estudo, organizado em 13 notebooks sequenciais (extração, limpeza, partição, análise exploratória, tratamento da pandemia, SARIMAX, engenharia de atributos, aprendizado de máquina local e global, TimesFM, combinações, visão geral da validação e resultados finais), está disponível em: https://github.com/GbrImoraes/brazil_tourism_forecasting_benchmark